

# 考试复习-6-8

## 第六章 插值与逼近

### 6.1 Lagrange 插值

### 6.2 Newton插值多项式

### 6.3 Hermite插值

### 6.4 分段插值

### 6.5 【了解】样条插值

### 6.6 最小二乘法

### 6.7 正交多项式

## 第七章 数值积分

### 7.1 数值积分

### 7.2 插值型求积分公式

### 7.3 复化梯形与复化 Simpson

### 7.4 Gauss 型求积分公式

## 第八章 常微分方程数值解法

注意第 6—8 章概念较抽象，最好不要直接硬记，而是结合课后习题在具体情境中运用这些概念，通过做题把抽象内容落到可操作步骤，再反过来理解原理并形成清晰框架。

## 第六章 插值与逼近

在只知道函数若干节点值的情况下，构造一个在这些节点上完全一致的函数，用它代替未知的原函数。满足节点值的函数叫**插值函数**，构造它的过程叫**插值**。

若给定  $n+1$  个互异节点  $x_0, \dots, x_n$  与数值  $y_k$ ，则满足插值条件的次数  $\leq n$  的多项式存在且唯一。

这意味着无论用什么插值方法，不管你用 Lagrange 形式还是 Newton 形式来构造插值多项式，它们本质上是同一个多项式，因此它们的余项（误差项）也必须完全一致（意味着做完题可用待定系数法验证）

## 6.1 Lagrange 插值

### Lagrange 基函数

$$l_k(x) = \frac{x - x_0}{x_k - x_0} \cdot \frac{x - x_1}{x_k - x_1} \cdots \frac{x - x_{k-1}}{x_k - x_{k-1}} \cdot \frac{x - x_{k+1}}{x_k - x_{k+1}} \cdots \frac{x - x_n}{x_k - x_n} = \prod_{\substack{j=0 \\ j \neq k}}^n \frac{x - x_j}{x_k - x_j}$$

- 当  $x = x_k$  时，每一项都变成 1，所以  $l_k(x_k) = 1$ 。
- 当  $x = x_m$  ( $m \neq k$ ) 时，恰好有一项的分子变成 0，整串乘积变成 0，所以  $l_k(x_m) = 0$ 。

因此  $l_k(x)$  就是“在第  $k$  个节点为 1，其他节点为 0 的多项式开关”，用来拼出拉格朗日插值多项式。

### 拉格朗日插值多项式

$$L_n(x) = l_0(x)f_0 + l_1(x)f_1 + \cdots + l_n(x)f_n = \sum_{k=0}^n f_k l_k(x)$$

$$L_n(x_j) = \sum_{k=0}^n f_k l_k(x_j) = f_j$$

### Lagrange 插值多项式的误差公式-插值余项

对任意  $x \in [a, b]$ ，真实函数  $f(x)$  与插值多项式  $L_n(x)$  的误差为：

$$R_n(x) = f(x) - L_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \omega_{n+1}(x)$$

1. 分子是导数次数
2.  $\xi_x$  是一个随  $x$  而变，落在节点区间  $[x_0, x_n]$  里的某个数
3.  $\omega_{n+1}(x) = (x - x_0)(x - x_1) \cdots (x - x_n)$

这个就是 Lagrange 插值误差项（余项）。

若  $|f^{(n+1)}(x)|$  在区间  $[a, b]$  上有上界  $M_{n+1}$ ，

则 Lagrange 插值余项满足估计： $|R_n(x)| \leq \frac{M_{n+1}}{(n+1)!} |\omega_{n+1}(x)|$

所有多项式插值（无论拉格朗日、牛顿、范德蒙、分段构造……）的误差公式本质上都是：

$$R_n(x) = f(x) - p_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \omega_{n+1}(x),$$

$$\text{其中 } \omega_{n+1}(x) = (x - x_0)(x - x_1) \cdots (x - x_n) = \prod_{k=0}^n (x - x_k)$$

只依赖节点，不依赖插值形式。

补充：

$\omega_{k+1}(x)$  是一个过  $k+1$  个节点的  $(k+1)$  次多项式。

$\omega'_{k+1}(x_j)$  的意思就是把  $\omega_{k+1}(x)$  对  $x$  求导后，代入  $x = x_j$  的值：

$$\omega'_{k+1}(x_j) = \left. \frac{d}{dx} (x - x_0)(x - x_1) \cdots (x - x_k) \right|_{x=x_j}$$

$C^2[a, b] = \{ \text{在区间 } [a, b] \text{ 上连续且有连续一阶、二阶导数的函数} \}$  也就是：

- $S(x)$  在整个区间上连续；
- $S'(x)$  在整个区间上连续；
- $S''(x)$  在整个区间上连续。

连续即可求导！

## 6.2 Newton插值多项式

**一阶差商：两点的“离散导数”**

$$\text{给定两个互异节点 } x_i, x_j \ (i \neq j) : f[x_i, x_j] = \frac{f(x_j) - f(x_i)}{x_j - x_i}$$

**二阶差商：三个点的离散二阶导数**

对三个互异点  $x_i, x_j, x_k$  :

$$f[x_i, x_j, x_k] = \frac{f[x_j, x_k] - f[x_i, x_j]}{x_k - x_i}$$

**k 阶差商：逐级递推**

对于节点  $x_0, x_1, \dots, x_k$ ,  $k$  阶差商定义为:

$$f[x_0, x_1, \dots, x_k] = \frac{f[x_1, x_2, \dots, x_k] - f[x_0, x_1, \dots, x_{k-1}]}{x_k - x_0}$$

**最高阶差商 = 最高次项系数, 做k阶差商的结果就等于最高k阶幂的系数。**

$x_i$	$f(x_i)$	一阶差商	二阶差商	三阶差商	...	$n$ 阶差商
$x_0$	$f(x_0)$					
$x_1$	$f(x_1)$	$f[x_0, x_1]$				
$x_2$	$f(x_2)$	$f[x_1, x_2]$	$f[x_0, x_1, x_2]$			
$x_3$	$f(x_3)$	$f[x_2, x_3]$	$f[x_1, x_2, x_3]$	$f[x_0, x_1, x_2, x_3]$		
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\dots$	
$x_n$	$f(x_n)$	$f[x_{n-1}, x_n]$	$f[x_{n-2}, x_{n-1}, x_n]$	$f[x_{n-3}, x_{n-2}, x_{n-1}, x_n]$	$f[x_0, x_1, \dots, x_n]$	

### 重要性质

1. 若  $f(x)$  具有k阶连续导数, 则  $f(x)$  的k阶差商等价于函数某点的  $k$  阶导数

$$f[x_0, x_1, \dots, x_k] = \frac{f^{(k)}(\xi)}{k!}, \quad \xi \in (x_0, x_1, \dots, x_k) \text{ 之间的某个中间位置}$$

**2. 若  $f(x)$  是  $n$  次多项式, 则:**

- 当  $k \leq n$ :  $f[x_0, \dots, x_k]$  是一个  $(n - k)$  次多项式
- 当  $k > n$ :  $f[x_0, \dots, x_k] \equiv 0$

多项式的“阶数”随着差商减一层一层地下降, 超过极限后就变成 0, 就像连续求导一样。n 次多项式的  $n+1$  阶导数恒为 0。每做一次差商, 就是对多项式“做一次离散求导”。

3. 差商对节点排列不敏感,  $f[x_{i_0}, x_{i_1}, \dots, x_{i_k}] = f[x_0, x_1, \dots, x_k]$ , 顺序随便换。

### Newton插值多项式及其余项

Newton 插值把插值多项式写成一种逐层递推的形式:

$$N_n(x) = f(x_0) + (x - x_0)f[x_0, x_1] + \dots + \omega_n(x) f[x_0, \dots, x_n]$$

这种写法最大的特点是: 每增加一个新节点  $x_{k+1}$ , 只需要在原多项式后面再加一项, 因此具有天然的承袭性 (递推性):  $N_{k+1}(x) = N_k(x) + \omega_{k+1}(x)f[x_0, \dots, x_{k+1}]$ .

将这个递推展开式与函数  $f(x)$  的真实值比较, 可把  $f(x)$  本身也写成 Newton 形式:

$$f(x) = \sum_{k=0}^n \omega_k(x) f[x_0, \dots, x_k] + \omega_{n+1}(x) f[x_0, \dots, x_n, x].$$

前  $n$  项正是 Newton 插值多项式  $N_n(x)$ ，最后一项就是插值误差，因此自然得到余项：

$$R_n(x) = \omega_{n+1}(x) f[x_0, \dots, x_n, x].$$

由于插值多项式是唯一的，Lagrange 插值的余项与 Newton 的余项完全一致，也可以表示为

$$R_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \omega_{n+1}(x)$$

### 重节点差商

正常差商要求节点互异，但在 Newton 插值、Hermite 插值等场景里，可能出现同一个节点重复使用的情况，这时差商定义中出现 0 作分母，于是我们必须用极限重新定义。**重复节点差商就是导数，阶数越高，差商越像高阶导数除以阶乘。**

$$\text{一阶“重节点差商”： } f[x_0, x_0] = \lim_{x \rightarrow x_0} f[x_0, x] = \lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0} = f'(x_0)$$

$$\text{二阶“重节点差商”： } f[x_0, x_0, x_0] = \lim_{x \rightarrow x_0} \frac{f[x_0, x_0] - f[x_0, x]}{x_0 - x} = \frac{f''(x_0)}{2!}$$

$$\text{混合重复节点差商： } f[x_0, x_0, x_1] = \frac{f[x_0, x_1] - f[x_0, x_0]}{x_1 - x_0}$$

$$\text{这正是泰勒公式一阶余项的形式，也可写成： } f[x_0, x_0, x_1] = \frac{f''(\xi)}{2!}, \quad \xi \in (x_0, x_1)$$

总结：重节点差商与导数关系

如果  $f(x)$  足够光滑：

$$\underbrace{f[x_0, \dots, x_0]}_{k+1} = \frac{f^{(k)}(x_0)}{k!}$$

放到一般形式：

$$f[x_0, x_0, \dots, x_0, x_1] = \frac{f^{(k)}(\xi)}{k!} \quad (\xi \text{ 在区间内})$$

## 6.3 Hermite 插值

Hermite 插值多项式 = 不仅逼近函数值  $f(x)$ ，还同时逼近导数值  $f'(x)$ 、 $f''(x)$ ... 的插值多项式。

(带有导数插值条件的插值多项式称为 Hermite 插值多项式)

### 三次 Hermite 插值多项式求解步骤

确定三次插值多项式  $H_3(x)$ ，使满足条件：

$$H_3(x_0) = f(x_0) = y_0, \quad H_3(x_1) = f(x_1) = y_1,$$

$$H'_3(x_0) = f'(x_0) = y'_0, \quad H'_3(x_1) = f'(x_1) = y'_1.$$

注：满足以上插值条件的 Hermite 插值多项式是唯一存在的。

### 基函数法（结合具体题目理解）

步骤1：设  $H_3(x)$  表达式（构造四个专门的基函数）

这里面是2个函数，2个导数，但根据题目也可以设置3个函数，一个导数。

三次 Hermite 插值的核心规律只有一句：一个三次多项式只有 4 个自由度，所以无论你用“几个函数 + 几个导数”来构造，只要一共提供 4 条独立条件，就能唯一确定它。

因此可以是“2 个函数值 + 2 个导数值”，也可以是“3 个函数值 + 1 个导数值”，形式不同，本质相同，只要条件数凑满 4 个，方程就能解、多项式就能定。

Hermite 的技巧是：构造四个专门的“基函数”，每个基函数只满足自己的插值条件，其余条件全为 0。

$$H_3(x) = \varphi_0(x)y_0 + \varphi_1(x)y_1 + \psi_0(x)y'_0 + \psi_1(x)y'_1 \quad (1)$$

$$H'_3(x) = \varphi'_0(x)y_0 + \varphi'_1(x)y_1 + \psi'_0(x)y'_0 + \psi'_1(x)y'_1 \quad (2)$$

步骤2：分别将  $x_0$  和  $x_1$  代入 (1) 和 (2)：

$$\varphi_0(x_0) = 1, \quad \varphi_1(x_0) = 0, \quad \psi_0(x_0) = 0, \quad \psi_1(x_0) = 0$$

$$\varphi_0(x_1) = 0, \quad \varphi_1(x_1) = 1, \quad \psi_0(x_1) = 0, \quad \psi_1(x_1) = 0$$

$$\varphi'_0(x_0) = 0, \quad \varphi'_1(x_0) = 0, \quad \psi'_0(x_0) = 1, \quad \psi'_1(x_0) = 0$$

$$\varphi'_0(x_1) = 0, \quad \varphi'_1(x_1) = 0, \quad \psi'_0(x_1) = 0, \quad \psi'_1(x_1) = 1$$

步骤三：求基函数（一般就是这两种设的方式，具体题目再分析）

$$\varphi_0(x) = (x - x_1)^2(ax + b) \quad (\text{代入条件 } \varphi_0(x_0) = 1, \varphi'_0(x_0) = 0 \text{ 解 } a, b)$$

$$\varphi_1(x) = (x - x_0)^2(ax + b) \quad (\text{代入条件 } \varphi_1(x_1) = 1, \varphi'_1(x_1) = 0 \text{ 解 } a, b)$$

$$\psi_0(x) = C(x - x_1)^2(x - x_0) \quad (\text{代入条件 } \psi'_0(x_0) = 1, \psi'_0(x_1) = 0 \text{ 解出 } C)$$

$$\psi_1(x) = C(x - x_0)^2(x - x_1) \quad (\text{代入条件 } \psi'_1(x_1) = 1, \psi'_1(x_0) = 0 \text{ 解出 } C)$$

插值多项式余项

$$R_3(x) = f(x) - H_3(x) = \frac{f^{(4)}(\xi_x)}{4!}(x - x_0)^2(x - x_1)^2. \quad (\text{还是和上面误差一样的公式，后面的是 } \omega_{n+1}(x))$$

## 6.4 分段插值

Runge 现象简单说就是：在等距节点上使用高次多项式插值，越想提高精度，结果越容易在区间两端发生剧烈振荡，反而变差。可以采用分段插值方法。

注意误差公式

二次

若  $f \in C^2[a, b]$ ，则对任意  $x \in [x_{i-1}, x_i]$ ，

$$f(x) - S_1(x) = \frac{f''(\xi_i)}{2}(x - x_{i-1})(x - x_i)$$

$$\text{进一步估计: } ab \leq \left(\frac{a+b}{2}\right)^2 = \frac{(a+b)^2}{4}, \quad h_i = x_i - x_{i-1}, \quad h = \max_{1 \leq i \leq n} h_i$$

$x$  处于  $x_i$  和  $x_{i-1}$  之间的时候最大， $a+b=2$  倍的  $1/2$  区间！

$$|f(x) - S_1(x)| \leq \frac{M_2}{8}h^2, \quad M_2 = \max |f''(x)|.$$

三次

设一个距离  $a$ ，另外两个距离用  $a$  表示，求函数最大值即可

## 6.5 【了解】样条插值

样条插值的出发点是：用一条高次多项式穿过很多节点既不稳定也容易震荡，因此不如把区间切成许多小段，在每一小段上用低次（通常是三次）多项式来逼近。

为了让整条曲线看起来自然、平滑又没有折痕，各段之间不仅要求函数值连续（不折断），还要求一阶导数连续（方向一致、不出现尖角），甚至二阶导数也连续（曲率平滑，不出现突然的弯折）。在这些约束下，每一段的三次多项式被唯一确定，所有小段拼接成一条整体上  $C^2$  连续的插值曲线。

最终结果像一根柔软的竹条被固定在若干钉子的位置，通过自然弯曲形成的平滑曲线：既精准经过所有节点，又不会像高次多项式插值那样在区间两端剧烈震荡，同时改变某个节点时只会影响附近的少数几段，具有良好的稳定性与局部性。

简言之：

样条插值 = 分段多项式 + 低次（通常三次）+ 强制光滑拼接（函数值、一阶导、二阶导连续）= 一条自然、平稳、稳定的整体曲线。

## 6.6 最小二乘法

我们想找一个函数  $\varphi(x)$  来逼近一堆离散数据点  $(x_i, y_i)$ ，但这些点通常不在同一条光滑曲线上，所以不存在“精确插值”。因此我们引入“误差向量”：

$$\mathbf{e} = \begin{pmatrix} \varphi(x_0) - y_0 \\ \varphi(x_1) - y_1 \\ \vdots \\ \varphi(x_m) - y_m \end{pmatrix}$$

也就是说：每一维表示  $\varphi(x)$  在某个点与真实数据的差。真实目标不是让误差为零，而是让误差“整体最小”。于是我们度量误差向量的大小： $\|\mathbf{e}\|_2$  希望它最小。换句话说：寻找一个函数，使它在所有数据点上的误差平方和最小。这就是“最小二乘”。

拟合空间 = 你允许拟合函数所在的“函数集合 / 子空间”。

设一组基函数： $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$

它们的线性组合： $V = \text{span}\{\varphi_0, \varphi_1, \dots, \varphi_n\}$

这个空间  $V$  就叫 拟合空间。你的拟合函数  $\varphi(x)$  必须属于  $V$ 。

最小二乘法就是把数据向量投影到拟合空间  $V$  上。

例：二次最小二乘拟合

基函数： $\varphi_0(x) = 1, \quad \varphi_1(x) = x, \quad \varphi_2(x) = x^2$

拟合空间： $V = \text{span}\{1, x, x^2\}$

所有二次多项式都在这里。

### 求解步骤

(1) 选拟合函数 (2) 写基函数 (3) 写离散内积 (4) 列正规方程 (5) 解系数 (6) 写出拟合函数 (7) 算误差

已知数据：给定离散点  $(x_0, y_0), (x_1, y_1), \dots, (x_m, y_m)$ ，

(若有权重，就给  $p(x_i) > 0$ ，否则默认  $p(x_i) = 1$ )。

1. 选拟合函数空间，比如一次多项式： $\varphi(x) = p_1(x) = a_0 + a_1 x$

2. 写出基函数： $\varphi_0(x) = 1, \quad \varphi_1(x) = x$

(如果是二次，就再加一个  $\varphi_2(x) = x^2$ ，步骤同理。)

把每个基函数在所有采样点上的取值看成一个向量：

$$\varphi_0 = \begin{pmatrix} \varphi_0(x_0) \\ \varphi_0(x_1) \\ \vdots \\ \varphi_0(x_m) \end{pmatrix}, \quad \varphi_1 = \begin{pmatrix} \varphi_1(x_0) \\ \varphi_1(x_1) \\ \vdots \\ \varphi_1(x_m) \end{pmatrix},$$



数据向量：

$$\mathbf{f} = \begin{pmatrix} y_0 \\ y_1 \\ \vdots \\ y_m \end{pmatrix}$$

3. 向量内积（内积时一定要带权函数，若无权重，就取  $p(x_k) \equiv 1$ ）

$$(\varphi_i, \varphi_j) = \sum_{k=0}^m p(x_k) \varphi_i(x_k) \varphi_j(x_k) \quad \text{--对应的应该有4个式子}$$

$$(\mathbf{f}, \varphi_i) = \sum_{k=0}^m p(x_k) y_k \varphi_i(x_k) \quad \text{--对应的有2个式子}$$

4. 写出正规方程（正交条件）

最小二乘要求误差向量（误差 = 真实数据 - 拟合函数）

设拟合函数

$$\hat{f} = \sum_{i=0}^n a_i \varphi_i,$$

误差向量定义为

$$e = f - \hat{f} = f - \sum_{i=0}^n a_i \varphi_i.$$

最小二乘要求误差与拟合空间正交，即对所有基函数皆有：

$$(e, \varphi_i) = 0, \quad i = 0, 1, \dots, n.$$

将内积展开后，可得到  $(n+1) \times (n+1)$  的通用正规方程组：

$$\underbrace{\begin{pmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{pmatrix}}_{\text{Gram矩阵 } G} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} (f, \varphi_0) \\ (f, \varphi_1) \\ \vdots \\ (f, \varphi_n) \end{pmatrix}.$$

5. 求解该线性系统即可得到拟合系数  $a_0, a_1, \dots, a_n$ ：直接把上面的方程组按普通线性代数求解

6. 写出最小二乘拟合曲线： $\varphi^*(x) = p_n^*(x) = \sum_{i=0}^n a_i^* \varphi_i(x),$

7. 计算均方误差：

误差向量:

$$\mathbf{e} = \begin{pmatrix} \varphi^*(x_0) - y_0 \\ \varphi^*(x_1) - y_1 \\ \vdots \\ \varphi^*(x_m) - y_m \end{pmatrix}$$

带权 2-范数:

$$\|\mathbf{e}\|_2 = \left( \sum_{i=0}^m p(x_i) [\varphi^*(x_i) - y_i]^2 \right)^{1/2}$$

## 6.7 正交多项式

### 1. Schmidt 正交化 (Gram-Schmidt 正交化)

给定函数序列  $f_0(x), f_1(x), f_2(x), \dots$

构造正交函数序列  $g_0(x), g_1(x), g_2(x), \dots$

公式如下:

$$g_0(x) = f_0(x)$$

$$g_1(x) = f_1(x) - \frac{(f_1, g_0)}{(g_0, g_0)} g_0(x)$$

$$g_2(x) = f_2(x) - \frac{(f_2, g_0)}{(g_0, g_0)} g_0(x) - \frac{(f_2, g_1)}{(g_1, g_1)} g_1(x)$$

$$g_3(x) = f_3(x) - \frac{(f_3, g_0)}{(g_0, g_0)} g_0(x) - \frac{(f_3, g_1)}{(g_1, g_1)} g_1(x) - \frac{(f_3, g_2)}{(g_2, g_2)} g_2(x)$$

$\vdots$

其中内积一般取:

$$(f, g) = \int_a^b f(x)g(x) dx \quad \text{或带权内积} \quad (f, g) = \int_a^b f(x)g(x)w(x) dx.$$

### 2. 由 $1, x, x^2, \dots, x^n$ 经过 Schmidt 正交化可得到正交多项式

对基底

$$f_0(x) = 1, \quad f_1(x) = x, \quad f_2(x) = x^2, \dots$$

做 Schmidt (Gram-Schmidt) 正交化,

可得到一组在  $[a, b]$  上的 正交多项式序列

$$p_0(x), p_1(x), \dots, p_n(x)$$

正交的意义 = 让  $p_n(x)$  的零点恰好成为最优节点

正交性带来两个重要性质：

1. 正交多项式的根全部落在区间 (0,1)  
——自然成为求积节点，安全可靠。
2. 利用正交性，可以证明此节点选择使公式达最高阶  $2n-1$   
对  $n=2$  即达到 3 阶精度，不浪费自由度。

换句话说：正交多项式 + 取其零点 = 自动给出最优的 Gauss 节点

## 第七章 数值积分

### 7.1 数值积分

#### 基本概念

把积分想成“连续加和”，数值积分就是把这件事离散化：只在区间里选几个点，算出函数在这些点的值，再按一定权重加起来，去逼近真实的积分。不同的选点方式和权重组合，就得到不同的积分公式；它们的好坏取决于能否对一些简单函数（尤其是多项式）算得完全正确，也就是“代数精度”。代数精度越高，公式对一般函数的逼近也越准。

积分本来是“在整个区间上把无穷多个值累加”，数值积分做的事是把它改成“只看有限几个点”。于是把

$$\int_a^b f(x) dx \text{ 用一个加权求和来代替: } \int_a^b f(x) dx \approx \sum_{k=0}^n A_k f(x_k). \text{ 这里 } x_k \text{ 是你挑的采样}$$

点， $A_k$  是对应的权重。一个求积公式好不好，就看它对多项式能不能算准：如果对所有

$$f(x) = x^j, j = 0, \dots, m$$

都完全相等  $\int_a^b x^j dx = \sum_{k=0}^n A_k x_k^j$ ，那就说这个公式有  $m$  次代数精度。代数精度越高，公式对一般函数的积分也越接近真实值。

#### 求积分公式的代数精度

##### 1. 求积分式的一般形式

$$\int_a^b f(x) dx \approx \sum_{k=0}^n A_k f(x_k)$$

(其中  $x_k$  为节点,  $A_k$  为求积系数)

## 2. 代数精度 (m 次)

若求积公式

$$\int_a^b f(x) dx \approx \sum_{k=0}^n A_k f(x_k)$$

对  $f(x) = x^j$ ,  $j = 0, 1, \dots, m$  都精确成立, 但对  $f(x) = x^{m+1}$  不再精确,

$$\text{即: } \int_a^b x^j dx = \sum_{k=0}^n A_k x_k^j, \quad j = 0, 1, \dots, m$$

$$\int_a^b x^{m+1} dx \neq \sum_{k=0}^n A_k x_k^{m+1}$$

则称该求积公式具有 **m 次代数精度**。

使用待定系数法确定求积分公式的待定参数。

## 7.2 插值型求积分公式

插值型求积分公式的核心思想是: 在区间  $[a, b]$  上选取若干节点, 用通过这些节点的插值多项式

$$P_n(x) \text{ 近似函数 } f(x), \text{ 再把积分 } \int_a^b f(x) dx \text{ 替换为 } \int_a^b P_n(x) dx = \sum_{k=0}^n A_k f(x_k), \text{ 从而得到线性加权求和形式的数值积分公式。}$$

Newton—Cotes 公式是在区间  $[a, b]$  上取 **等距节点**  $x_k = a + kh$ , 用插值多项式来逼近  $f(x)$ , 再对插

值多项式作精确积分, 从而得到  $\int_a^b f(x) dx \approx \sum_{k=0}^n A_k f(x_k)$ , 其中  $A_k$  为插值积分得到的权系数。

常用的 **Newton—Cotes 公式 (需要都背出来)** 包括:

$$I = \int_a^b f(x) dx$$

选  $n+1$  个等距节点  $x_k = a + kh$ ,  $h = \frac{b-a}{n}$ .

对  $f(x)$  做  $n$  次插值  $P_n(x)$ , 积分近似为:

$$\int_a^b f(x) dx \approx \sum_{k=0}^n A_k f(x_k),$$

其中系数  $A_k$  由

$$A_k = \int_0^n l_k(t) dt \quad (l_k(t) \text{ 是 Lagrange 基函数})$$

通过等距节点积分得到。

误差项必定是负数。

**梯形公式** ( $n=1$ , 代数精度 1) :

$$T(h) = \frac{h}{2} [f(a) + f(b)]$$

误差项:

$$|I - T(h)| \leq \frac{(b-a)^3}{12} \max |f''(x)|$$

**Simpson 公式** ( $n=2$ , 代数精度 3) :

$$S(h) = \frac{h}{3} [f(a) + 4f(\frac{a+b}{2}) + f(b)]$$

误差项:

$$|I - S(h)| \leq \frac{(b-a)^5}{2880} \max |f^{(4)}(x)|$$

**3/8 公式** ( $n=3$ , 代数精度 3)

$$\int_a^b f(x) dx \approx \frac{3h}{8} [f(x_0) + 3f(x_1) + 3f(x_2) + f(x_3)]$$

误差项:

$$E = -\frac{(b-a)^5}{6480} f^{(4)}(\xi)$$

**Boole 公式** ( $n=4$ , 代数精度 5) —— 狭义的Cotes公式

$$\int_a^b f(x) dx \approx \frac{2h}{45} [7f(x_0) + 32f(x_1) + 12f(x_2) + 32f(x_3) + 7f(x_4)]$$

误差项:

$$E = -\frac{(b-a)^7}{1935360} f^{(6)}(\xi)$$

记忆方法：

“前面的系数” × “括号里所有整数之和” 必须等于 “总区间长度  $nh$ ”

梯形： $\frac{h}{2}(1+1) = 1h$

Simpson： $\frac{h}{3}(1+4+1) = 2h$

Simpson 3/8： $\frac{3h}{8}(1+3+3+1) = 3h$

Cotes 4 点： $\frac{2h}{45}(7+32+12+32+7) = 4h$

对于标准的“下凸”函数（导数大于0），这些求积公式计算出的面积往往比真实面积大（过高估计）。所以这些误差都是负数。

### 误差项如何记忆

#### 规律一：导数阶数（奇偶跃迁）

这是最重要的性质，决定了公式准不准。

- **n 是奇数** (1, 3)：导数阶数是 **n+1**。
  - 梯形 ( $n=1$ )  $\rightarrow f''$
  - Simp 3/8 ( $n=3$ )  $\rightarrow f^{(4)}$
- **n 是偶数** (2, 4)：导数阶数是 **n+2**（超收敛，多送一阶精度！）。
  - Simpson ( $n=2$ )  $\rightarrow f^{(4)}$
  - Cotes ( $n=4$ )  $\rightarrow f^{(6)}$

#### 规律二：幂次跟随导数

误差项中  $(b-a)$  的幂次，永远比导数阶数 大 1。

- $f''$ (2阶)  $\rightarrow (b-a)^3$
- $f^{(4)}$ (4阶)  $\rightarrow (b-a)^5$
- $f^{(6)}$ (6阶)  $\rightarrow (b-a)^7$

阶数 (n)	名称	导数阶数(决定精度)	误差项系数(记住分母)	误差项公式 $R[f]$
1	梯形	2	$-\frac{1}{12}$	$-\frac{(b-a)^3}{12} f''(\xi)$
2	Simpson	4	$-\frac{1}{80}$	$-\frac{(b-a)^5}{80} f^{(4)}(\xi)$
3	Simpson 3/8	4	$-\frac{3}{80}$	$-\frac{3(b-a)^5}{80} f^{(4)}(\xi)$
4	Cotes	6	$-\frac{1}{945}$	$-\frac{(b-a)^7}{945} f^{(6)}(\xi)$

1 (奇)	梯形	$f''$ (2阶)	12	$-\frac{(b-a)^3}{12} f''(\xi)$
2 (偶)	Simpson	$f^{(4)}$ (4阶)	2880	$-\frac{(b-a)^5}{2880} f^{(4)}(\xi)$
3 (奇)	Simpson 3/8	$f^{(4)}$ (4阶)	6480	$-\frac{(b-a)^5}{6480} f^{(4)}(\xi)$
4 (偶)	Cotes	$f^{(6)}$ (6阶)	1935360	$-\frac{(b-a)^7}{1935360} f^{(6)}(\xi)$

## 7.3 复化梯形与复化 Simpson

复化在数值积分里指的是：把一个大区间分成很多小子区间，在每个小区间上应用一次低阶求积公式，然后把所有小区间的结果加起来。

把  $[a, b]$  等分成  $n$  段，步长  $h = \frac{b-a}{n}$ ， $x_k = a + kh$ 。

在每一段  $[x_k, x_{k+1}]$  上都套一次你喜欢的求积公式（比如梯形、Simpson）。

### 1. 复化梯形

$$\text{公式: } \int_a^b f(x) dx \approx \frac{h}{2} \left[ f(a) + 2 \sum_{k=1}^{n-1} f(x_k) + f(b) \right]$$

$$\text{误差估计: } |I - T_n| \leq \frac{(b-a)^3}{12n^2} M_2, \quad \left( M_2 = \max_{a \leq x \leq b} |f''(x)| \right)$$

（其中  $n$  为区间等分数）

### 2. 复化 Simpson 【重点】

$$\text{公式: } \int_a^b f(x) dx \approx \frac{h}{6} \left[ f(a) + 4 \sum_{k=1}^n f(x_{k-\frac{1}{2}}) + 2 \sum_{k=1}^{n-1} f(x_k) + f(b) \right]$$

$$\text{误差估计: } |I - S_n| \leq \frac{(b-a)^5}{2880n^4} M_4, \quad \left( M_4 = \max_{a \leq x \leq b} |f^{(4)}(x)| \right)$$

复化Simpson有中点出现，一般取两段。

## 7.4 Gauss 型求积公式

### 1. Gauss 型求积公式的定义

$$\int_a^b \rho(x) f(x) dx \approx \sum_{i=1}^n A_i f(x_i) \quad (\text{从1开始})$$

如果某求积公式具有  $2n-1$  次代数精度，则其对应的节点  $x_1, x_2, \dots, x_n$  称为 **Gauss 点**，此时的求积公式称为 **Gauss 型求积公式**。

(注) 为讨论方便，本节取  $n$  个节点，并记节点为  $x_1, x_2, \dots, x_n$ ，同时，所讨论的积分均为带权函数  $\rho(x)$  的积分。

## 2. 构造 Gauss 型求积公式的步骤——重要

(1) 对给定区间  $[a, b]$  和权函数  $\rho(x)$ ，由 **Schmidt 正交化过程构造正交多项式**  $P_0(x), P_1(x), \dots, P_n(x)$ 。

(2) 求出  $P_n(x)$  的  $n$  个零点  $x_1, x_2, \dots, x_n$ ，即为 **Gauss 点**。

(3) 计算求积系数  $A_i = \int_a^b \rho(x) l_i(x) dx, i = 1, 2, \dots, n$ ，其中  $l_i(x)$  为节点  $x_i$  对应的 Lagrange 基函数。

## 变形的 Gauss 型求积公式—记住权函数

### 1. Gauss—Legendre 求积公式

区间：  $[-1, 1]$

权函数：  $\rho(x) = 1$

特殊的：

从  $p_0$  开始构造正交多项式 (Legendre 多项式)

权函数  $\rho(x) = 1$ ，区间  $[-1, 1]$ ，使用 三项递推公式

$$p_0(x) = 1, \quad p_1(x) = x$$

$$(n+1)p_{n+1}(x) = (2n+1)xp_n(x) - np_{n-1}(x)$$

**Gauss—Legendre 求积权重 通用公式：**

$$w_i = \frac{2}{(1-x_i^2)[P'_n(x_i)]^2}$$

### 2. Gauss—Laguerre 求积公式

区间：  $[0, +\infty)$

权函数：  $\rho(x) = e^{-x}$

### 3. Gauss—Hermite 求积公式



区间:  $(-\infty, +\infty)$

权函数:  $\rho(x) = e^{-x^2}$

只要是  $n$  点 Gauss 型求积 (不管是哪种权函数), 它的代数精度总是:  $2n - 1$

看题目要求精确到几次多项式, 用  $2n - 1 \geq m$  判断所需的节点数。

或者根据给出的节点数  $n$  自动知道精度是  $2n - 1$ 。

例 1: 题目说“对  $1, x, x^2$  都精确”  $\rightarrow$  最高次  $m = 2$

$$2n - 1 \geq 2 \Rightarrow n \geq 2.$$

所以用  $n=2$  点 Gauss 就够了。

例 2: 题目要求“三点 Gauss 求积公式”

那就是  $n=3 \rightarrow$  代数精度 automatically 是:

$$2 \times 3 - 1 = 5 \text{ (五次精度)}$$

看到  $\sqrt{\frac{1}{3}}$  就是 2 点公式，看到  $\sqrt{\frac{3}{5}}$  就是 3 点公式。这是记忆 Gauss-Legendre 积分节点最直观的方法。四阶比较复杂，不需要记忆！

标准积分区间为  $[-1, 1]$ ，公式形式为：

$$\int_{-1}^1 f(x) dx \approx \sum_{k=1}^n A_k f(x_k)$$

1. 两点 Gauss 公式 ( $n=2$ )

关键词：  $\pm\sqrt{\frac{1}{3}}$

这是最基础的公式，代数精度为  $2n - 1 = 3$

- 节点 ( $x_k$ ):  $\pm\frac{1}{\sqrt{3}}$
- 权重 ( $A_k$ ): 均为 1

完整公式：  $\int_{-1}^1 f(x) dx \approx 1 \cdot f\left(-\frac{1}{\sqrt{3}}\right) + 1 \cdot f\left(\frac{1}{\sqrt{3}}\right)$

2. 三点 Gauss 公式 ( $n=3$ )

关键词：  $\pm\sqrt{\frac{3}{5}}$  和 0

代数精度为  $2n - 1 = 5$ 。由于是对称区间，中间节点一定是 0。

- 节点 ( $x_k$ ):  $0, \pm\sqrt{\frac{3}{5}}$
- 权重 ( $A_k$ ): 中间点为  $\frac{8}{9}$ ，两端点为  $\frac{5}{9}$

完整公式：  $\int_{-1}^1 f(x) dx \approx \frac{5}{9} f\left(-\sqrt{\frac{3}{5}}\right) + \frac{8}{9} f(0) + \frac{5}{9} f\left(\sqrt{\frac{3}{5}}\right)$

### 正交多项式适用情况

情况	节点是否全给?	任务目标	是否必须正交?
Gauss 求积公式	✗ 节点未知	目标=达到最高代数精度 = $2n-1$	✓ 必须正交求节点（最优）

一般求积公式构造	— 节点部分已给 but 未说明最优	只需使代数精度尽可能高但有限制	✗ 直接列代数方程即可
题目未要求最优性，只求系数	— 甚至节点未知	精度达到几阶是自然结果	✗ 无需正交

**Gauss** 这个词本身就意味着：在给定节点数时达到最高代数精度。也就是说题目虽然没写，但逻辑上已经默认：这是 Gauss 公式的定义，不需要题目额外声明。也就意味着这时候当节点未知的时候，需要进行正交多项式！

### Romberg公式

k (分段)	T0 (梯形值)	T1 (一次外推)	T2 (二次外推)	T3 (三次外推)
0 (1段)	$T_0^{(0)}$			
1 (2段)	$T_0^{(1)} \rightarrow$	$T_1^{(0)}$		
2 (4段)	$T_0^{(2)} \rightarrow$	$T_1^{(1)} \rightarrow$	$T_2^{(0)}$	
3 (8段)	$T_0^{(3)} \rightarrow$	$T_1^{(2)} \rightarrow$	$T_2^{(1)} \rightarrow$	$T_3^{(0)}$ -结果

**Romberg (龙贝格) 求积法** 是一种用于计算定积分数值解的高精度算法。

简单来说，它的核心思想是：“由粗糙变精细”。它并不直接使用一个超级复杂的公式去计算积分，而是先用最简单的公式算出几个“粗糙”的结果，然后通过数学上的**外推技术**（Richardson 外推），把这些粗糙的结果组合起来，消除误差，从而得到一个非常精确的最终结果。

以下是通俗易懂的原理拆解：

#### 1. 核心构成：两个“法宝”

Romberg 算法由两部分组成：

- 复化梯形公式 (Trapezoidal Rule)**：这是基础。通过不断把积分区间一分为二（加密网格），计算出一列近似值。
- Richardson (理查森) 外推法**：这是加速器。利用梯形公式的误差规律，通过线性组合消除误差项，从而极大地提高精度。

#### 2. 具体操作步骤

想象我们要计算积分  $I = \int_a^b f(x)dx$  。

第一步：造“梯形序列”（第一列数据）

初始值公式（第一列  $T_0$ ）

在套用上面的公式之前，必须先算出第一列  $T_0^{(k)}$ 。这列数据就是**复化梯形公式**的值。

对于积分  $I = \int_a^b f(x)dx$ ：

$k = 0$  (1段):

- $T_0^{(0)} = \frac{b-a}{2}[f(a) + f(b)]$

$k > 0$  (递推计算  $2^k$  段):

为了减少计算量，通常用递推法算  $T_0$ ：

- $T_0^{(k)} = \frac{1}{2}T_0^{(k-1)} + h_k \sum_{i=1}^{2^{k-1}} f(x_{new})$

- 其中  $h_k = \frac{b-a}{2^k}$  是当前的步长。

- $\sum f(x_{new})$  表示只把**新增加的分点**的函数值加起来。

我们先用梯形公式计算积分，但是每次都把步长  $h$  减半（即区间分段数翻倍）：

- $T_0^{(0)}$ ：把区间分成 1 段（用梯形公式算一次）。
- $T_0^{(1)}$ ：把区间分成 2 段（算一次）。
- $T_0^{(2)}$ ：把区间分成 4 段（算一次）。
- ...以此类推。

这一列数据虽然精度在提高，但收敛速度比较慢。

第二步：用公式“加速”（生成后续列）

我们利用 Richardson 外推公式，把第一列的数据两两结合，生成第二列、第三列.....

通用的递推公式是：

$$T_m^{(k)} = \frac{4^m T_{m-1}^{(k+1)} - T_{m-1}^{(k)}}{4^m - 1}$$

- 其中  $m$  代表外推的阶数（第几列）， $k$  代表分段的层级。

符号含义：

- $T$ ：代表积分的近似值。
- $m$ ：代表**外推的阶数**（即在这个表中是第几列）。

- $m=1$  时, 分母是  $4^1 - 1 = 3$  (对应 Simpson 公式)。
- $m=2$  时, 分母是  $4^2 - 1 = 15$  (对应 Cotes 公式)。
- $m=3$  时, 分母是  $4^3 - 1 = 63$ 。

•  $k$ : 代表二分加密的次数 (即在这个表中是第几行)。

$$R = B + \frac{B - A}{4^m - 1}$$

- 第 1 次外推 ( $m=1$ ):  $R = \frac{4B - A}{3}$
- 第 2 次外推 ( $m=2$ ):  $R = \frac{16B - A}{15}$
- 第 3 次外推 ( $m=3$ ):  $R = \frac{64B - A}{63}$

这个规律非常工整, 分母总是  $4^m - 1$ , 分子总是“精细值的  $4^m$  倍”减去“粗糙值”。

## 补充

### 积分中值定理:

若  $f$  在  $[a, b]$  上连续, 则存在  $\xi \in (a, b)$ , 使得:

$$\int_a^b f(x) dx = f(\xi)(b - a)$$

含义: 积分就是“区间长度  $\times$  某个点的函数值”。这个点一定存在, 但一般找不到具体值。

拓展:

若:

- $g(x)$  在  $[a, b]$  上连续,
- $w(x)$  在  $[a, b]$  上不变号 (即全  $\geq 0$  或全  $\leq 0$ ),

则存在某个  $\xi \in (a, b)$ , 使得:

$$\int_a^b g(x) w(x) dx = g(\xi) \int_a^b w(x) dx$$

### 拉格朗日中值定理:

对可导函数  $f$ , 在区间  $[a, b]$  上存在一点  $\xi_x$ , 使得:

$$f(b) - f(a) = f'(\xi)(b - a)$$

对可导函数  $f$ , 在区间  $[x, b]$  上存在一点  $\xi_x$ , 使得:

$$f(b) - f(x) = f'(\xi_x)(b - x)$$

可导函数  $f$ , 在区间  $[a, x]$  上存在一点  $\xi_x$ , 使得:

$$f(x) - f(a) = f'(\xi_x)(x - a)$$

$f(b) - f(a)$  只与端点  $a, b$  有关, 不依赖  $x$ 。

写成  $\xi_x$  会暗示  $\xi_x$  随  $x$  变化, 这是错误的。

区间	正确的中值定理写法	是否可写成 $\xi_x$
$[a, b]$	$f(b) - f(a) = f(\xi)(b - a)$	✗ 不能写 $\xi_x$ (与 $x$ 无关)
$[x, b]$	$f(b) - f(x) = f(\xi_x)(b - x)$	✓ 可以写 $\xi_x$
$[a, x]$	$f(x) - f(a) = f(\xi_x)(x - a)$	✓ 可以写 $\xi_x$

### 泰勒公式 (含拉格朗日余项)

原始Taylor公式: 
$$f(x) = \sum_{k=0}^{\infty} \frac{f^{(k)}(a)}{k!} (x - a)^k$$

带余项的Taylor公式: 
$$f(x) = \sum_{k=0}^n \frac{f^{(k)}(a)}{k!} (x - a)^k + R_{n+1}$$

设  $f$  在点  $x = a$  的某邻域内  $n+1$  次可导, 则对任意  $x$  有:

$$f(x) = \sum_{k=0}^n \frac{f^{(k)}(a)}{k!} (x - a)^k + \frac{f^{(n+1)}(\xi)}{(n+1)!} (x - a)^{n+1}$$

其中  $\xi \in (a, x)$  或  $\xi \in (x, a)$ 。

例如三阶: 
$$f(x) = f(a) + f'(a)(x - a) + \frac{f''(a)}{2}(x - a)^2 + \frac{f^{(3)}(\xi_x)}{6}(x - a)^3$$

泰勒公式的阶由 余项的阶数 决定

## 第八章 常微分方程数值解法

一阶常微分方程初值问题的一般形式为:

$$\begin{cases} \frac{dy}{dx} = f(x, y), & a \leq x \leq b, \\ y(a) = \alpha \end{cases}$$

(其中  $y$  是  $x$  的已知函数,  $\alpha$  为给定的初值)

### Lipschitz (利普希茨条件)

若函数  $f(x,y)$  在区域  $\{a \leq x \leq b, m < y < M\}$  上连续, 且关于  $y$  满足 Lipschitz (利普希茨) 条件:

$$|f(x, y) - f(x, \bar{y})| \leq L|y - \bar{y}|$$

对所有  $y, \bar{y}$  成立, 其中  $L > 0$  为 Lipschitz 常数, 则初值问题 (在上述区域内) 存在唯一解。

【注】此时 Lipschitz 常数  $L$  不必小于 1!

#### 【例 1】

$$\begin{cases} \frac{dy}{dx} = 1 + x \sin(xy), & 0 \leq x \leq 2, \\ y(0) = 1 \end{cases}$$

解: 设  $f(x, y) = 1 + x \sin(xy)$

对任意  $y, \bar{y}$ , 对变量  $y$  应用微分中值定理, 存在  $\eta$ , 使得

$$\frac{f(x, y) - f(x, \bar{y})}{y - \bar{y}} = \frac{\partial}{\partial y} f(x, y) = x^2 \cos(x\eta)$$

于是  $|f(x, y) - f(x, \bar{y})| = |x^2 \cos(x\eta)| |y - \bar{y}| \leq 4|y - \bar{y}|$

因为此时  $f(x,y)$  关于  $y$  满足 Lipschitz 条件, 且常数  $L=4$ 。

因此, 从理论上讲, 初值问题存在惟一解。

### 差分公式的格式

1. Euler公式:  $y_{n+1} = y_n + hf(x_n, y_n)$
2. 梯形公式:  $y_{n+1} = y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, y_{n+1})]$
3. Euler中点公式:  $y_{n+1} = y_{n-1} + 2hf(x_n, y_n)$
4. 改进Euler方法的两种格式

格式1:

$$\begin{cases} \bar{y}_{n+1} = y_n + hf(x_n, y_n) \\ y_{n+1} = y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, \bar{y}_{n+1})] \\ y_0 = \alpha, \quad n = 0, 1, 2, \dots, N-1 \end{cases}$$

格式2

$$\begin{cases} y_{n+1} = y_n + \frac{h}{2}(k_1 + k_2) \\ k_1 = f(x_n, y_n) \\ k_2 = f(x_n + h, y_n + hk_1) \\ y_0 = \alpha, \quad n = 0, 1, 2, \dots, N-1 \end{cases}$$

**改进的Euler方法** (Improved Euler Method)，又被称为**Heun方法** (Heun's Method) 或**预测-校正法** (Predictor-Corrector Method)，是对经典Euler方法的一种优化。简单来说，经典Euler方法只看“脚下”的斜率来决定下一步往哪走，而改进的Euler方法会先试探性地走一步，看看终点的斜率，然后取两者的平均值来决定真正的步伐。

### 1. 核心公式（预测-校正机制）

改进的Euler方法将计算分为两步：

预测：先用标准的Euler公式算出一个“粗糙”的预估值  $\tilde{y}_{n+1}$ 。

$$1. \quad \tilde{y}_{n+1} = y_n + h \cdot f(x_n, y_n)$$

校正：利用刚才预测到的点算出终点斜率，将起点斜率和终点斜率取平均，再算一次真正的  $y_{n+1}$ 。

$$2. \quad y_{n+1} = y_n + \frac{h}{2} \left[ \underbrace{f(x_n, y_n)}_{\text{起点斜率}} + \underbrace{f(x_{n+1}, \tilde{y}_{n+1})}_{\text{预估的终点斜率}} \right] \quad (\text{这个是已经将 } k_1, k_2 \text{ 代入了})$$

### 2. 几何意义：梯形公式

- 经典Euler方法相当于做矩形积分（左矩形公式），它假设这一步长内斜率不变，误差较大。
- 改进的Euler方法相当于做梯形积分。它认为这一段路上的斜率是在变化的，用“起点斜率”和“终点斜率”的平均值来代表这一段的平均变化率，从而让走出的直线更贴近真实的曲线。

**局部截断误差**  $y(x_{n+1}) - y_{n+1}$

#### 1. 局部截断误差的阶数

若差分格式的局部截断误差为  $O(h^{p+1})$ ，则称该公式为  $p$  阶公式。

#### 2. Taylor公式

一元 Taylor 公式：

$$y(x_{n+1}) = y(x_n + h) = y(x_n) + y'(x_n)h + \frac{y''(x_n)}{2!}h^2 + \frac{y^{(3)}(x_n)}{3!}h^3 + O(h^4)$$

二元 Taylor 公式：



$$f(x + \Delta x, y + \Delta y) = f + f_x \Delta x + f_y \Delta y + \frac{1}{2}(f_{xx} \Delta x^2 + 2f_{xy} \Delta x \Delta y + f_{yy} \Delta y^2) + O(\Delta x^3 + \Delta y^3)$$

### 3. $y'(x_n), y''(x_n), y'''(x_n)$ 公式

因为  $y'(x) = f(x, y(x))$ ，所以若  $y(x_n) = y_n$ ，则有：

$$y'(x_n) = f(x_n, y(x_n)) = f(x_n, y_n) = f_n$$

$$y''(x_n) = \frac{\partial f(x_n, y_n)}{\partial x} + \frac{\partial f(x_n, y_n)}{\partial y} y'(x_n) = \frac{\partial f_n}{\partial x} + \frac{\partial f_n}{\partial y} f_n$$

$$y'''(x_n) = \frac{\partial^2 f_n}{\partial x^2} + 2 \frac{\partial^2 f_n}{\partial x \partial y} f_n + \frac{\partial^2 f_n}{\partial y^2} f_n^2 + \frac{\partial f_n}{\partial x} \frac{\partial f_n}{\partial y} + \left( \frac{\partial f_n}{\partial y} \right)^2 f_n$$

### 4. 关于改进 Euler 方法的局部截断误差分析

改进 Euler 方法格式：

$$\begin{cases} y_{n+1} = y_n + \frac{h}{2}(k_1 + k_2) \\ k_1 = f(x_n, y_n) \\ k_2 = f(x_n + h, y_n + hk_1) \\ y_0 = \alpha, \quad n = 0, 1, 2, \dots, N-1 \end{cases}$$

以下考试重点内容

## 常见 R-K 格式（直接可用）

### ① 二阶 R-K（含 Euler 改进法）

常见两种：Heun 公式（梯形思想）

$$\begin{cases} k_1 = f(x_n, y_n) \\ k_2 = f(x_n + h, y_n + hk_1) \\ y_{n+1} = y_n + \frac{h}{2}(k_1 + k_2) \end{cases}$$

中点 R-K2

$$\begin{cases} k_1 = f(x_n, y_n) \\ k_2 = f(x_n + \frac{h}{2}, y_n + \frac{h}{2}k_1) \\ y_{n+1} = y_n + hk_2 \end{cases}$$

均为2阶，局部截断误差  $O(h^3)$ 。

### ② 三阶 R-K（考试常考）

$$\begin{cases} k_1 = f(x_n, y_n) \\ k_2 = f(x_n + \frac{h}{2}, y_n + \frac{h}{2}k_1) \\ k_3 = f(x_n + h, y_n - hk_1 + 2hk_2) \\ y_{n+1} = y_n + \frac{h}{6}(k_1 + 4k_2 + k_3) \end{cases}$$

阶数：3阶，误差  $O(h^4)$ 。

### ③ 四阶经典 R-K4（必须背）

$$\begin{cases} k_1 = f(x_n, y_n) \\ k_2 = f(x_n + \frac{h}{2}, y_n + \frac{h}{2}k_1) \\ k_3 = f(x_n + \frac{h}{2}, y_n + \frac{h}{2}k_2) \\ k_4 = f(x_n + h, y_n + hk_3) \\ y_{n+1} = y_n + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4) \end{cases}$$

最常用、四阶误差  $O(h^5)$ 。工程/仿真普遍采用。

## 判断单步方法的收敛性

步骤：

1. 写出  $\Phi$  : 根据题目给出的格式, 识别出  $y_{n+1} = y_n + h[\dots]$  中括号里的部分就是  $\Phi$  。

2. 验证相容性: 令  $h=0$ , 看  $\Phi$  是否等于  $f(x, y)$ 。(通常显式单步法都满足)。

3. 验证 Lipschitz:

◦ 对  $\Phi$  求  $y$  的偏导数  $\frac{\partial \Phi}{\partial y}$ 。

◦ 如果  $f(x, y)$  本身满足 Lipschitz 条件 (即  $\left| \frac{\partial f}{\partial y} \right| \leq L$ ) , 且  $\Phi$  是  $f$  的线性组合, 那么通常  $\left| \frac{\partial \Phi}{\partial y} \right|$  也是有界的。

◦ 结论: 因为偏导数有界, 所以满足 Lipschitz 条件  $\rightarrow$  方法收敛。

会求单步方法的 **绝对稳定区域、稳定区间**。

Step 1: 代入模型方程

将  $y' = \lambda y$  代入数值公式。即把所有的  $f(x_k, y_k)$  替换为  $\lambda y_k$ 。

Step 2: 提取  $E(z)$

整理方程, 使得左边只剩  $y_{n+1}$ , 右边提取出公因式  $y_n$ 。将出现的  $\lambda h$  替换为  $z$ 。

形式必然是:  $y_{n+1} = E(z)y_n$ 。

Step 3: 解不等式

求解  $|E(z)| < 1$ 。

- 如果是求区域 (复平面), 通常是画图 (比如内部是一个圆)。
- 如果是求区间 (实数), 直接解代数不等式  $-1 < E(z) < 1$ 。

题目：求显式 Euler 法  $y_{n+1} = y_n + hf(x_n, y_n)$  的绝对稳定区间。

解答步骤：

代入模型方程：

将  $f(x_n, y_n) = \lambda y_n$  代入公式：

$$1. \quad y_{n+1} = y_n + h(\lambda y_n)$$

整理得到  $E(z)$ ：

$$2. \quad y_{n+1} = (1 + h\lambda)y_n$$

令  $z = h\lambda$ ，得：

$$3. \quad y_{n+1} = (1 + z)y_n$$

所以，稳定函数为  $E(z) = 1 + z$ 。

求解稳定区间：

我们需要  $|E(z)| < 1$ ，即：

$$4. \quad |1 + z| < 1$$

对于实数区间，即：

$$5. \quad -1 < 1 + z < 1$$

同时减去 1：

$$6. \quad -2 < z < 0$$

结论：

- 显式 Euler 法的绝对稳定区域是复平面上以  $(-1, 0)$  为圆心，半径为 1 的圆的内部。
- 显式 Euler 法的绝对稳定区间是  $(-2, 0)$ 。

在常微分方程 (ODE) 的标准写法中，我们总是写成：

$$y' = f(x, y)$$

这里的等号告诉我们要怎么理解：

- 左边的  $y'$  代表导数（即斜率）。
- 右边的  $f(x, y)$  代表计算导数的规则。