

## 第3章 解线性方程组的迭代法

## 回顾: 关于线性方程组

$$\left\{ \begin{array}{l} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2 \\ \dots\dots\dots \\ a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n = b_n \end{array} \right. \quad (3.1)$$

的直接解法,其主要不足之处在于:

1. 在有舍入误差的情况下，一般得到的仍是近似解.
2. 当问题规模较大时，算法所需的计算量仍然很大，而且计算过程中所累计误差的影响会“越来越坏”. 因而，此类算法一般只适用于中小规模的“稠密”型方程组.
3. 算法程序的设计一般也比较复杂.

线性方程组(的古典定常)迭代法的基本思想是: 把 $n$ 元线性方程组

[illegible]

或  $Ax=b.$

## 改写成等价的方程组

$$\begin{cases} x_1 = m_{11}x_1 + m_{12}x_2 + \cdots + m_{1n}x_n + g_1 \\ x_2 = m_{21}x_1 + m_{22}x_2 + \cdots + m_{2n}x_n + g_2 \\ \quad \quad \quad \dots \dots \\ x_n = m_{n1}x_1 + m_{n2}x_2 + \cdots + m_{nn}x_n + g_n \end{cases},$$

或

$$x=Mx+g.$$

由此建立方程组的迭代公式

$$\mathbf{x}^{(k+1)} = \mathbf{M}\mathbf{x}^{(k)} + \mathbf{g}, \quad k=0, 1, 2, \dots \quad (3.2)$$

其中 $\mathbf{M}$ 称为**迭代矩阵**. 对任意取定的初始向量 $\mathbf{x}^{(0)}$ , 由(3.2)式可逐次算出迭代向量 $\mathbf{x}^{(k)}$ ,  $k=1, 2, \dots$

如果向量序列 $\{\mathbf{x}^{(k)}\}$ 收敛于 $\mathbf{x}^*$ , 由(3.2)式可得

$$\mathbf{x}^* = \mathbf{M}\mathbf{x}^* + \mathbf{g},$$

从而 $\mathbf{x}^*$ 是方程组 $\mathbf{x} = \mathbf{M}\mathbf{x} + \mathbf{g}$ 的解, 也就是方程组 $\mathbf{A}\mathbf{x} = \mathbf{b}$ 的解.

这种求解线性方程组的方法称为**迭代法**, 若迭代序列 $\{\mathbf{x}^{(k)}\}$ 收敛, 则称迭代法**收敛**, 否则称迭代法**发散**.

## 迭代法的特点:

1. 可以在迭代过程中对误差进行“校正”；
2. 可以保持问题的稀疏结构. 当收敛性能较好时, 其总体计算量也可能会较小, 因而适用于大规模稀疏型问题的计算.
3. 这类算法的程序设计一般比较简单;
4. 一般只能求得近似解.

## 问题:

1. 如何建立具体的迭代格式?
2. 如何保证或判断迭代格式是否收敛?
3. 如何控制迭代收敛的速度?

# Jacobi (雅可比)迭代法 和

## 考虑线性方程组

[illegible]

当 $a_{ii} \neq 0$ 时,  $i=1, 2, \dots, n$ , 由方程组(3.1)得到等价方程组:

$$\begin{cases} x_1 = \frac{-a_{12}}{a_{11}}x_2 - \frac{a_{13}}{a_{11}}x_3 - \cdots - \frac{a_{1n}}{a_{11}}x_n + \frac{b_1}{a_{11}}, \\ x_2 = \frac{-a_{21}}{a_{22}}x_1 - \frac{a_{23}}{a_{22}}x_3 - \cdots - \frac{a_{2n}}{a_{22}}x_n + \frac{b_2}{a_{22}}, \\ \dots\dots\dots \\ x_n = \frac{-a_{n1}}{a_{nn}}x_1 - \frac{a_{n2}}{a_{nn}}x_2 - \cdots - \frac{a_{n,n-1}}{a_{nn}}x_{n-1} + \frac{b_n}{a_{nn}}. \end{cases}$$

从而可构造相应的迭代格式:

$$\begin{cases} x_1^{(k+1)} = \frac{-a_{12}}{a_{11}}x_2^{(k)} - \frac{a_{13}}{a_{11}}x_3^{(k)} - \cdots - \frac{a_{1n}}{a_{11}}x_n^{(k)} + \frac{b_1}{a_{11}}, \\ x_2^{(k+1)} = \frac{-a_{21}}{a_{22}}x_1^{(k)} - \frac{a_{23}}{a_{22}}x_3^{(k)} - \cdots - \frac{a_{2n}}{a_{22}}x_n^{(k)} + \frac{b_2}{a_{22}}, \\ \dots\dots\dots \\ x_n^{(k+1)} = \frac{-a_{n1}}{a_{nn}}x_1^{(k)} - \frac{a_{n2}}{a_{nn}}x_2^{(k)} - \cdots - \frac{a_{n,n-1}}{a_{nn}}x_{n-1}^{(k)} + \frac{b_n}{a_{nn}}. \end{cases}$$

初始向量 $\mathbf{x}^{(0)}=(x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^T$ .

$k=0, 1, 2, \dots$

$$\begin{cases} x_1^{(k+1)} = \frac{-a_{12}}{a_{11}}x_2^{(k)} - \frac{a_{13}}{a_{11}}x_3^{(k)} - \dots - \frac{a_{1n}}{a_{11}}x_n^{(k)} + \frac{b_1}{a_{11}}, \\ x_2^{(k+1)} = \frac{-a_{21}}{a_{22}}x_1^{(k)} - \frac{a_{23}}{a_{22}}x_3^{(k)} - \dots - \frac{a_{2n}}{a_{22}}x_n^{(k)} + \frac{b_2}{a_{22}}, \\ \dots \dots \dots \\ x_n^{(k+1)} = \frac{-a_{n1}}{a_{nn}}x_1^{(k)} - \frac{a_{n2}}{a_{nn}}x_2^{(k)} - \dots - \frac{a_{n,n-1}}{a_{nn}}x_{n-1}^{(k)} + \frac{b_n}{a_{nn}}. \end{cases} \quad (3.3)$$

$k=0, 1, 2, \dots$

式(3.3)称为**Jacobi迭代法**, 简称为**J迭代法**.

**J**迭代法也记为

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right),$$

$$i=1, 2, \dots, n; k=0, 1, 2, \dots$$

可见, J迭代法的迭代矩阵为

$$\mathbf{B} = \begin{pmatrix} 0 & \frac{-a_{12}}{a_{11}} & \cdots & \frac{-a_{1n}}{a_{11}} \\ \frac{-a_{21}}{a_{22}} & 0 & \cdots & \frac{-a_{2n}}{a_{22}} \\ \cdots & \cdots & \cdots & \cdots \\ \frac{-a_{n1}}{a_{nn}} & \cdots & \frac{-a_{n,n-1}}{a_{nn}} & 0 \end{pmatrix}.$$

若记  $\mathbf{g} = \left( \frac{b_1}{a_{11}} \quad \frac{b_2}{a_{22}} \quad \cdots \quad \frac{b_n}{a_{nn}} \right)^T$ , 则J迭代法可写成

$$\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{g}, \quad k=0, 1, 2, \dots$$



若在**J**迭代法中充分利用新值, 则可以得到如下新格式:

$$\begin{cases} x_1^{(k+1)} = \frac{-a_{12}}{a_{11}}x_2^{(k)} - \frac{a_{13}}{a_{11}}x_3^{(k)} - \dots - \frac{a_{1n}}{a_{11}}x_n^{(k)} + \frac{b_1}{a_{11}} \\ x_2^{(k+1)} = \frac{-a_{21}}{a_{22}}x_1^{(\textcolor{red}{k}+1)} - \frac{a_{23}}{a_{22}}x_3^{(k)} - \dots - \frac{a_{2n}}{a_{22}}x_n^{(k)} + \frac{b_2}{a_{22}}, \\ \dots \dots \dots \\ x_n^{(k+1)} = \frac{-a_{n1}}{a_{nn}}x_1^{(\textcolor{red}{k}+1)} - \frac{a_{n2}}{a_{nn}}x_2^{(\textcolor{red}{k}+1)} - \dots - \frac{a_{n,n-1}}{a_{nn}}x_{n-1}^{(\textcolor{red}{k}+1)} + \frac{b_n}{a_{nn}} \end{cases}$$

$$k=0, 1, 2, \dots \quad (3.4)$$

式(3.4)称为**Gauss-Seidel**迭代法(的分量形式), 简称为**G-S**迭代法.

**G-S**迭代法也可记为

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(\textcolor{red}{k}+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right),$$

$$i=1, 2, \dots, n; k=0, 1, 2, \dots$$

## 例1 用J法和G-S法求解线性方程组

[回到例2](#)

$$\begin{cases} 10x_1 + 3x_2 + x_3 = 14 \\ 2x_1 - 10x_2 + 3x_3 = -5 \\ x_1 + 3x_2 + 10x_3 = 14 \end{cases}$$

方程组的精确解为 $\mathbf{x}^*=(1, 1, 1)^T$ .

解: J迭代法计算公式为

$$\begin{cases} x_1^{(k+1)} = -\frac{3}{10}x_2^{(k)} - \frac{1}{10}x_3^{(k)} + \frac{7}{5} \\ x_2^{(k+1)} = \frac{1}{5}x_1^{(k)} + \frac{3}{10}x_3^{(k)} + \frac{1}{2} \\ x_3^{(k+1)} = -\frac{1}{10}x_1^{(k)} - \frac{3}{10}x_2^{(k)} + \frac{7}{5} \end{cases}$$

取初始向量 $\mathbf{x}^{(0)}=(0, 0, 0)^T$ , 迭代计算结果列表如下:

$k$	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$	$\ \mathbf{x}^{(k)}-\mathbf{x}^*\ _\infty$
0	0	0	0	1
1	1.4000	0.5000	1.4000	0.5000
2	1.1100	1.2000	1.1100	0.2000
3	0.9290	1.0550	0.9290	0.0710
4	0.9906	0.9645	0.9906	0.0355
5	1.0116	0.9953	1.0116	0.0116
6	1.0003	1.0058	1.0003	0.0058

可见，迭代序列逐次收敛于方程组的解，而且迭代6次得到精确到小数点后两位的近似解.

**G-S**迭代法的计算公式为:

$$\begin{cases} x_1^{(k+1)} = -\frac{3}{10}x_2^{(k)} - \frac{1}{10}x_3^{(k)} + \frac{7}{5} \\ x_2^{(k+1)} = \frac{1}{5}x_1^{(k+1)} + \frac{3}{10}x_3^{(k)} + \frac{1}{2} \\ x_3^{(k+1)} = -\frac{1}{10}x_1^{(k+1)} - \frac{3}{10}x_2^{(k+1)} + \frac{7}{5} \end{cases}$$

同样取初始向量 $\mathbf{x}^{(0)}=(0, 0, 0)^T$ , 计算结果为

$k$	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$	$\ \mathbf{x}^{(k)}-\mathbf{x}^*\ _\infty$
0	0	0	0	1
1	1.4000	0.7800	1.0260	0.4000
2	1.0634	1.0205	0.9875	0.0634
3	0.9951	0.9953	1.0019	0.0049
4	1.0012	1.0008	0.9996	0.0012

$k$	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$	$\ \mathbf{x}^{(k)} - \mathbf{x}^*\ _\infty$
0	0	0	0	1
1	1.4000	0.7800	1.0260	0.4000
2	1.0634	1.0205	0.9875	0.0634
3	0.9951	0.9953	1.0019	0.0049
4	1.0012	1.0008	0.9996	0.0012

可见G-S迭代法收敛较快. 取精确到小数点后两位的近似解, G-S迭代法只需迭代3次, 而J迭代法需要迭代6次.

为了进一步研究, 从矩阵计算角度来讨论上述迭代法.

对线性方程组  $A\mathbf{x}=\mathbf{b}$ , 记

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ a_{21} & a_{22} & a_{23} & \cdots & a_{2n} \\ a_{31} & a_{32} & a_{33} & \cdots & \cdots \\ \cdots & \cdots & \cdots & & a_{n-1,n} \\ a_{n1} & a_{n2} & \cdots & a_{n,n-1} & a_{nn} \end{pmatrix},$$

以及.....

$$\mathbf{D} = \begin{pmatrix} a_{11} & & & & \\ & a_{22} & & & \\ & & a_{33} & & \\ & & & \dots & \\ & & & & a_{nn} \end{pmatrix},$$

$$-\mathbf{L} = \begin{pmatrix} 0 & & & & \\ a_{21} & 0 & & & \\ a_{31} & a_{32} & 0 & & \\ \dots & \dots & \dots & \dots & \\ a_{n1} & a_{n2} & \dots & a_{n,n-1} & 0 \end{pmatrix},$$

$$-\mathbf{U} = \begin{pmatrix} 0 & a_{12} & a_{13} & \dots & a_{1n} \\ & 0 & a_{23} & \dots & a_{2n} \\ & & 0 & \dots & \dots \\ & & & \dots & a_{n-1,n} \\ & & & & 0 \end{pmatrix},$$

则有**矩阵分裂**:  $A = D + (-L) + (-U) = D - L - U$ .

于是线性方程组  $Ax = b$  可写成

$$(D - L - U)x = b.$$

以下分别采用不同的策略各自建立相应的迭代格式.

## 格式1

对原方程组采用以下方式移项整理, 可得等价方程组:

$$Dx = (L + U)x + b.$$

当矩阵  $A$  的对角元素都不为0时, 矩阵  $D$  可逆, 此时有

$$x = D^{-1}(L + U)x + D^{-1}b.$$

由此建立迭代公式

$$x^{(k+1)} = D^{-1}(L + U)x^{(k)} + D^{-1}b, \quad k = 0, 1, 2, \dots$$



或写成

$$\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{g}, \quad k=0,1,2,\dots$$

其中

$$\mathbf{B} = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}) = \begin{pmatrix} 0 & \frac{-a_{12}}{a_{11}} & \dots & \frac{-a_{1n}}{a_{11}} \\ \frac{-a_{21}}{a_{22}} & 0 & \dots & \frac{-a_{2n}}{a_{22}} \\ \dots & \dots & \dots & \dots \\ \frac{-a_{n1}}{a_{nn}} & \dots & \frac{-a_{n,n-1}}{a_{nn}} & 0 \end{pmatrix}, \quad \mathbf{g} = \mathbf{D}^{-1}\mathbf{b} = \begin{pmatrix} \frac{b_1}{a_{11}} \\ \frac{b_2}{a_{22}} \\ \dots \\ \frac{b_n}{a_{nn}} \end{pmatrix}$$

**Jacobi迭代矩阵**

经观察可知: 此格式就是 Jacobi迭代格式.

**Jacobi迭代格式 (矩阵形式)**

$$\mathbf{x}^{(k+1)} = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x}^{(k)} + \mathbf{D}^{-1}\mathbf{b}, \quad k=0,1,2,\dots$$

**Jacobi迭代矩阵**

## 格式2

对原方程组

$$(\mathbf{D}-\mathbf{L}-\mathbf{U})\mathbf{x}=\mathbf{b}$$

采用以下方式移项整理, 可得等价形式:

$$(\mathbf{D}-\mathbf{L})\mathbf{x}=\mathbf{U}\mathbf{x}+\mathbf{b}.$$

当矩阵 $\mathbf{A}$ 的对角元素都不为0时, 矩阵 $\mathbf{D}-\mathbf{L}$ 可逆, 此时有

$$\mathbf{x}=(\mathbf{D}-\mathbf{L})^{-1}\mathbf{U}\mathbf{x}+(\mathbf{D}-\mathbf{L})^{-1}\mathbf{b}.$$

由此建立迭代公式

$$\mathbf{x}^{(k+1)}=(\mathbf{D}-\mathbf{L})^{-1}\mathbf{U}\mathbf{x}^{(k)}+(\mathbf{D}-\mathbf{L})^{-1}\mathbf{b}, k=0,1,2,\dots$$

思考: 这是什么格式?

事实上, 对于J迭代法

$$\mathbf{x}^{(k+1)} = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x}^{(k)} + \mathbf{D}^{-1}\mathbf{b}, \quad k=0, 1, 2, \dots$$

可以写为:  $\mathbf{x}^{(k+1)} = \mathbf{D}^{-1}\mathbf{L}\mathbf{x}^{(k)} + \mathbf{D}^{-1}\mathbf{U}\mathbf{x}^{(k)} + \mathbf{D}^{-1}\mathbf{b}$ .

按照G-S迭代改善的思路, 构造相应的新格式

$$\mathbf{x}^{(k+1)} = \mathbf{D}^{-1}\mathbf{L}\mathbf{x}^{(k+1)} + \mathbf{D}^{-1}\mathbf{U}\mathbf{x}^{(k)} + \mathbf{D}^{-1}\mathbf{b},$$

即:  $\mathbf{D}\mathbf{x}^{(k+1)} = \mathbf{L}\mathbf{x}^{(k+1)} + \mathbf{U}\mathbf{x}^{(k)} + \mathbf{b},$

也即:  $(\mathbf{D} - \mathbf{L})\mathbf{x}^{(k+1)} = \mathbf{U}\mathbf{x}^{(k)} + \mathbf{b},$

也即:  $\mathbf{x}^{(k+1)} = (\mathbf{D} - \mathbf{L})^{-1}\mathbf{U}\mathbf{x}^{(k)} + (\mathbf{D} - \mathbf{L})^{-1}\mathbf{b},$

就是刚才的  
格式2

**G-S迭代格式 (矩阵形式)**

$$\mathbf{x}^{(k+1)} = (\mathbf{D} - \mathbf{L})^{-1}\mathbf{U}\mathbf{x}^{(k)} + (\mathbf{D} - \mathbf{L})^{-1}\mathbf{b}, \quad k=0, 1, 2, \dots$$

其中, G-S格式的迭代矩阵为:  $\mathbf{G} = (\mathbf{D} - \mathbf{L})^{-1}\mathbf{U}$ .

## § 3.2 迭代法的收敛性

讨论迭代法

$$\mathbf{x}^{(k+1)} = \mathbf{M}\mathbf{x}^{(k)} + \mathbf{g}, \quad k=0, 1, 2, \dots$$

的收敛性.

记误差向量  $\mathbf{e}^{(k)} = \mathbf{x}^{(k)} - \mathbf{x}^*$ , 则迭代法收敛就是

$$\mathbf{e}^{(k)} \rightarrow \mathbf{0}, \quad (k \rightarrow \infty).$$

由于

$$\mathbf{x}^{(k+1)} = \mathbf{M}\mathbf{x}^{(k)} + \mathbf{g}, \quad k=0, 1, 2, \dots$$

$$\mathbf{x}^* = \mathbf{M}\mathbf{x}^* + \mathbf{g},$$

所以

$$\mathbf{e}^{(k+1)} = \mathbf{M}\mathbf{e}^{(k)}, \quad k=0, 1, 2, \dots$$

递推可得

$$\mathbf{e}^{(k)} = \mathbf{M}^k \mathbf{e}^{(0)}, \quad k=0, 1, 2, \dots$$

由以上讨论可见:

对任意的初始误差向量 $\mathbf{e}^{(0)}$ , 迭代解 $\mathbf{e}^{(k)} \rightarrow \mathbf{0} \ (k \rightarrow \infty) \Leftrightarrow \mathbf{M}^k \rightarrow \mathbf{0}$ .

思考: 上述迭代收敛的等价条件实际应用中是否方便?

**定理3.1** 迭代法 $\mathbf{x}^{(k+1)} = \mathbf{M}\mathbf{x}^{(k)} + \mathbf{g}$ 对任意初始向量 $\mathbf{x}^{(0)}$ 都收敛的等价条件是:  $\rho(\mathbf{M}) < 1$ .

**证明:1. 必要性.** 若迭代法收敛, 则 $\|\mathbf{M}^k\| \rightarrow 0$ , 于是有

$$\rho^k(\mathbf{M}) = \rho(\mathbf{M}^k) \leq \|\mathbf{M}^k\| \rightarrow 0,$$

所以 $\rho(\mathbf{M}) < 1$ .

**2. 充分性.** 若 $\rho(\mathbf{M}) < 1$ , 则存在 $\varepsilon > 0$ , 使得 $\rho(\mathbf{M}) + \varepsilon < 1$ .

于是存在某矩阵范数 $\|\cdot\|_\beta$ , 使得

$$\|\mathbf{M}^k\|_\beta \leq \|\mathbf{M}\|_\beta^k \leq [\rho(\mathbf{M}) + \varepsilon]^k \rightarrow 0.$$

可知此时迭代法收敛.

综上, 证毕.

注1：定理3.1是关于迭代法收敛性的一个基本定理.

注2：定理3.1的结论是面向“任意初始向量都收敛”的情形的.

对于**某些特殊的初始向量**，即使迭代格式不满足“ $\rho(M) < 1$ ”的条件，也有可能收敛.

注3：谱半径 $\rho(M)$ 一般不容易计算.

但是, 根据定理3.1还可以得到以下充分性判据.

**推论：** 对于迭代法 $\mathbf{x}^{(k+1)}=\mathbf{M}\mathbf{x}^{(k)}+\mathbf{g}$ , 若迭代矩阵 $\mathbf{M}$ 的某个矩阵范数 $\|\mathbf{M}\|_{\beta}<1$ , 则此迭代法对任意初始向量 $\mathbf{x}^{(0)}$ 都收敛.

例1

$$\mathbf{M} = \begin{bmatrix} 0.8 & 0.05 \\ 0.1 & 0.7 \end{bmatrix}$$

由于 $\|\mathbf{M}\|_1=0.9 < 1$ ,

于是可知 $\rho(\mathbf{M}) \leq \|\mathbf{M}\|_1 < 1$

事实上 $\rho(\mathbf{M})=0.8366$

因此, 此时迭代法收敛.

注: 此推论只是充分性条件, 而非必要性条件. 见下例.

## 例2

$$\mathbf{M} = \begin{bmatrix} 0.8 & 0 \\ 0.5 & 0.7 \end{bmatrix}$$

可得

$$\|\mathbf{M}\|_1 = 1.3 \geq 1;$$

$$\|\mathbf{M}\|_\infty = 1.2 \geq 1;$$

$$\|\mathbf{M}\|_2 = 1.0455 \geq 1;$$

$$\|\mathbf{M}\|_F = 1.1747 \geq 1,$$

但是

$$\rho(\mathbf{M}) = 0.8 < 1.$$

因此, 此时迭代法还是收敛的.

**结论:** 即使迭代矩阵 $\mathbf{M}$ 有“很多”个范数值都不小于1, 迭代也未必不收敛.



**定理 3.2:** 设矩阵  $M$  的某个矩阵范数  $\|M\| < 1$ , 则迭代法  $\mathbf{x}^{(k+1)} = M\mathbf{x}^{(k)} + \mathbf{g}$  对任意的初始向量  $\mathbf{x}^{(0)}$  收敛, 且满足以下条件:

$$\|\mathbf{x}^{(k)} - \mathbf{x}^*\| \leq \frac{\|M\|}{1 - \|M\|} \|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\| \quad (3.16)$$

$$\|\mathbf{x}^{(k)} - \mathbf{x}^*\| \leq \frac{\|M\|^k}{1 - \|M\|} \|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\| \quad (3.17)$$

上述两个不等式中的**矩阵范数与向量范数相容**.

思考: 这两个不等式的意义.

注: 此定理的结论只有在满足 “ $\|M\| < 1$ ” 的条件下才适用.

证明： 由于

$$\begin{aligned}\mathbf{x}^{(k+1)} &= \mathbf{M}\mathbf{x}^{(k)} + \mathbf{g}, \\ \mathbf{x}^{(k)} &= \mathbf{M}\mathbf{x}^{(k-1)} + \mathbf{g}, \\ \mathbf{x}^* &= \mathbf{M}\mathbf{x}^* + \mathbf{g},\end{aligned}$$

所以

$$\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} = \mathbf{M}(\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}), \quad \mathbf{x}^{(k+1)} - \mathbf{x}^* = \mathbf{M}(\mathbf{x}^{(k)} - \mathbf{x}^*).$$

于是有  $\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| \leq \|\mathbf{M}\| \|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|$ ,  $\|\mathbf{x}^{(k+1)} - \mathbf{x}^*\| \leq \|\mathbf{M}\| \|\mathbf{x}^{(k)} - \mathbf{x}^*\|$ .

从而,  $\|\mathbf{x}^{(k)} - \mathbf{x}^*\| = \|(\mathbf{x}^{(k)} - \mathbf{x}^{(k+1)}) + (\mathbf{x}^{(k+1)} - \mathbf{x}^*)\|$   
 $\leq \|\mathbf{x}^{(k)} - \mathbf{x}^{(k+1)}\| + \|\mathbf{x}^{(k+1)} - \mathbf{x}^*\| \leq \|\mathbf{M}\| \|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\| + \|\mathbf{M}\| \|\mathbf{x}^{(k)} - \mathbf{x}^*\|.$

所以可得

$$\|\mathbf{x}^{(k)} - \mathbf{x}^*\| \leq \frac{\|\mathbf{M}\|}{1 - \|\mathbf{M}\|} \|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|.$$

第一个不等式(3.16)

又由于  $\|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\| \leq \|\mathbf{M}\| \|\mathbf{x}^{(k-1)} - \mathbf{x}^{(k-2)}\| \leq \dots \leq \|\mathbf{M}\|^{k-1} \|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\|$ ,  
 代入第一个不等式(3.16)即得

$$\|\mathbf{x}^{(k)} - \mathbf{x}^*\| \leq \frac{\|\mathbf{M}\|^k}{1 - \|\mathbf{M}\|} \|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\|.$$

第二个不等式 (3.17)

证毕.

注1: 此定理的前提条件是 $\|M\| < 1$ . 否则此定理结论未必成立.

注2:  $\|M\| < 1$ 是指 $M$ 的某个范数(不必是所有范数)小于1.

注3: 此定理不等式中的向量范数与矩阵范数必须相容.

可见， **$\|M\|$ 越小收敛越快**，且当 $\|M\|<1$ ， $\|x^{(k)}-x^{(k-1)}\|$ 很小时， $\|x^{(k)}-x^*\|$ 就很小，实际上用 $\|x^{(k)}-x^{(k-1)}\|<\varepsilon$ 作为迭代终止的条件. 以下算例在实际计算中(**在确定 $\|M\|<1$ 的前提下**)可以通过设置指标 $\|x^{(k)}-x^{(k-1)}\|$ 来观察迭代是否收敛.

$k$	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$	$\ x^{(k)}-x^*\ _\infty$
0	0	0	0	1
1	1.4	0.5	1.4	0.5
2	1.11	1.20	1.11	0.2
3	0.929	1.055	0.929	0.071
4	0.9906	0.9645	0.9906	0.0355
5	1.01159	0.9953	1.01159	0.01159
6	1.000251	1.005795	1.000251	0.005795
7	0.9982364	1.0001255	0.9982364	0.0017636

由定理3.2还可以事先估计需要迭代多少步可达到所需的精度要求.

若使 $\|\mathbf{x}^{(k)} - \mathbf{x}^*\| < \varepsilon$ , 只需

$$\frac{\|\mathbf{M}\|^k}{1 - \|\mathbf{M}\|} \|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\| < \varepsilon,$$

即

$$k > \frac{\ln \left( \frac{\varepsilon(1 - \|\mathbf{M}\|)}{\|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\|} \right)}{\ln \|\mathbf{M}\|},$$

最后取满足这个不等式的最小的正整数(向上取整)即可.

**例2** 用J迭代法求例1中方程组的解, 取 $\mathbf{x}^{(0)}=(0, 0, 0)^T$ , 若使误差 $\|\mathbf{x}^{(k)}-\mathbf{x}^*\|_\infty < 10^{-5}$ , 问迭代多少次可满足此要求?

**解** 由例1([回看例1](#))知,  $\mathbf{x}^{(1)}=(1.4, 0.5, 1.4)^T$ ,

$$\mathbf{B} = \begin{pmatrix} 0 & \frac{-3}{10} & \frac{-1}{10} \\ \frac{1}{5} & 0 & \frac{3}{10} \\ \frac{-1}{10} & \frac{-3}{10} & 0 \end{pmatrix}.$$

于是有  $\|\mathbf{x}^{(1)}-\mathbf{x}^{(0)}\|_\infty=1.4$ ,  $\|\mathbf{B}\|_\infty=0.5$ .

$k$ 应满足  $k > \ln\left(\frac{0.5 \times 10^{-5}}{1.4}\right) / \ln 0.5 \approx 18.095$

故取 $k=19$ , 即迭代19次可满足此要求.

**注:** 按定理3.2中的不等式估算出的 $k$ 值一般比实际精确的 $k$ 值要稍大一些, 这是合理的. 想一想为什么.

## 补充知识点:

对同一个迭代矩阵 $\mathbf{M}$ , 取不同的矩阵范数时,  $\|\mathbf{M}\|$ 值也不相同. 但根据范数的等价性可知: 当迭代收敛时这些范数值都是比较小的数值, 并且此时谱半径 $\rho(\mathbf{M})$ 也一定都是比较小的. 事实上可以定义渐进收敛速度 $R(\mathbf{M})$ 如下:

$$R(\mathbf{M}) = \lim_{k \rightarrow \infty} \frac{-\ln \|\mathbf{M}^k\|}{k} = -\ln \rho(\mathbf{M})$$

可见迭代速度的快慢本质上取决于谱半径的大小.  $\rho(\mathbf{M})$ 越小, 收敛速度越快.

对于任意矩阵范数的  
极限都是如此

### § 3.3 J迭代法和G-S迭代法的收敛性

**定理3.3** 对任意的迭代初始向量,

J迭代法收敛 $\Leftrightarrow \rho(B) < 1$ ;

$B$ 的某个(给定的)范数 $\|B\|_\beta < 1 \Rightarrow$  J迭代法收敛;

G-S迭代法收敛 $\Leftrightarrow \rho(G) < 1$ ;

$G$ 的某个(给定的)范数 $\|G\|_\beta < 1 \Rightarrow$  G-S迭代法收敛;

以上判据都是通过观察迭代矩阵的性质来判断迭代是否收敛.

**问题:** 在一定条件下, 是否有更“简单”的方法(譬如, 直接观察系数矩阵的性质)来判断迭代法的收敛性?



**定义3.1** 若 $n$ 阶方阵 $A=(a_{ij})$ 满足:

$$\sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| < |a_{ii}|, \quad i=1, 2, \dots, n.$$

则称矩阵 $A$ 是(按行)严格对角占优矩阵.

$$A = \begin{pmatrix} \color{red}{a_{11}} & a_{12} & a_{13} & \dots & a_{1n} \\ a_{21} & \color{red}{a_{22}} & a_{23} & \dots & a_{2n} \\ a_{31} & a_{32} & \color{red}{a_{33}} & \dots & \dots \\ \dots & \dots & \dots & & a_{n-1,n} \\ a_{n1} & a_{n2} & \dots & a_{n,n-1} & \color{red}{a_{nn}} \end{pmatrix}.$$

**引理** 若 $A$ 是严格对角占优矩阵, 则 $\det(A) \neq 0$ .

**证明:** 易见

$$A = D - L - U = D[E - D^{-1}(L + U)] = D(E - B).$$

因为 $A$ 是严格对角占优矩阵, 所以 $\det(D) \neq 0$ , 而且

$$B = \begin{bmatrix} 0 & \frac{-a_{12}}{a_{11}} & \cdots & \frac{-a_{1n}}{a_{11}} \\ \frac{-a_{21}}{a_{22}} & 0 & \cdots & \frac{-a_{2n}}{a_{22}} \\ \cdots & \cdots & \cdots & \cdots \\ \frac{-a_{n1}}{a_{n,n}} & \cdots & \frac{-a_{n,n-1}}{a_{n,n}} & 0 \end{bmatrix}. \quad \|B\|_{\infty} = \max_{1 \leq i \leq n} \sum_{\substack{j=1 \\ j \neq i}}^n \left| \frac{a_{ij}}{a_{ii}} \right| < 1.$$

因此,  $\rho(B) \leq \|B\|_{\infty} < 1$ , 故 $\lambda = 1$ 不是 $B$ 的特征值,  $\det(E - B) \neq 0$ .

所以,  $\det(A) \neq 0$ . 证毕.

**注:** 上述过程顺便也证明了: 此时方程组 $Ax = b$ 的J迭代法是收敛的.

**定理3.4** 设 $A$ 是严格对角占优矩阵, 则解线性方程组 $Ax=b$ 的J迭代法和G-S迭代法(对任意的迭代初始向量)均收敛.

**证明:** 由于 $\|B\|_{\infty} < 1$ , 所以J迭代法收敛.

以下证明G-S迭代法收敛. 设 $\lambda$ 是 $G$ 的任一特征值, 则 $\lambda$ 满足特征方程

$$\det(\lambda E - G) = 0.$$

即:

$$\det(\lambda E - (D - L)^{-1}U) = 0.$$

也即:

$$\det[(D - L)^{-1}] \det[\lambda(D - L) - U] = 0.$$

它等价的方程为:  $\det[\lambda(D - L) - U] = 0.$  (\*)

采用反证法. 若 $|\lambda| \geq 1$ , 由于 $A = D - L - U$ 严格对角占优, 而

$$\lambda(D - L) - U = \begin{pmatrix} \lambda a_{11} & a_{12} & \cdots & a_{1n} \\ \lambda a_{21} & \lambda a_{22} & \cdots & a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ \lambda a_{n1} & \lambda a_{n2} & \cdots & \lambda a_{nn} \end{pmatrix}.$$

$$\lambda(\mathbf{D} - \mathbf{L}) - \mathbf{U} = \begin{pmatrix} \lambda a_{11} & a_{12} & \dots & a_{1n} \\ \lambda a_{21} & \lambda a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ \lambda a_{n1} & \lambda a_{n2} & \dots & \lambda a_{nn} \end{pmatrix}.$$

由于

$$\begin{aligned} |\lambda| |a_{ii}| &> |\lambda| \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| = \sum_{\substack{j=1 \\ j \neq i}}^{i-1} |\lambda| |a_{ij}| + \sum_{j=i+1}^n |\lambda| |a_{ij}| \\ &\geq \sum_{j=1}^{i-1} |\lambda| |a_{ij}| + \sum_{j=i+1}^n |a_{ij}|. \end{aligned}$$

可见 $|\lambda| \geq 1$ 时矩阵 $\lambda(\mathbf{D}-\mathbf{L})-\mathbf{U}$ 也是严格对角占优的. 这与(\*)式结论  $\det(\lambda(\mathbf{D}-\mathbf{L})-\mathbf{U})=0$  矛盾. 所以不可能有 $|\lambda| \geq 1$ , 只能 $|\lambda| < 1$ .

由于 $\lambda$ 是 $\mathbf{G}$ 的任意特征值, 于是可得 $\rho(\mathbf{G}) < 1$ . 因此G-S迭代法收敛. 证毕.

**定理3.5** 设 $A$ 是对称正定矩阵, 则解方程组 $Ax=b$ 的**G-S**迭代法(对任意的迭代初始向量)是收敛的.

此定理是定理3.9的推论.

注: 当 $A$ 是对称正定矩阵时, 方程组 $Ax=b$ 的**J**迭代法未必(对任意的迭代初始向量)收敛.

反例参见教材P56.

但是...

**补充定理**(P68: 3-14) 设 $A$ 是对称正定矩阵, 则解方程组 $Ax=b$ 的**J**迭代法(对任意的迭代初始向量)收敛 $\Leftrightarrow 2D-A$ 也正定.

**例3** 请针对线性方程组

$$\begin{cases} 2x_1 + 3x_2 + 6x_3 = 1 \\ 4x_1 - x_2 + 2x_3 = -2 \\ x_1 + 5x_2 + 2x_3 = 4 \end{cases}$$

建立(对任意的迭代初始向量)收敛的迭代格式, 说明理由.

**解** 先将原方程组(预处理)化为新的等价方程组:

$$\begin{cases} 4x_1 - x_2 + 2x_3 = -2, \\ x_1 + 5x_2 + 2x_3 = 4, \\ 2x_1 + 3x_2 + 6x_3 = 1. \end{cases}$$

建立迭代格式

$$\begin{cases} x_1^{(k+1)} = \frac{1}{4}x_2^{(k)} - \frac{1}{2}x_3^{(k)} - \frac{1}{2}, \\ x_2^{(k+1)} = \frac{-1}{5}x_1^{(k)} - \frac{2}{5}x_3^{(k)} + \frac{4}{5}, \\ x_3^{(k+1)} = \frac{-1}{3}x_1^{(k)} - \frac{1}{2}x_2^{(k)} + \frac{1}{6}. \end{cases}$$

由于新的方程组的系数矩阵是严格对角占优的. 而迭代格式是对这个方程组应用了Jacobi迭代法, 由定理3.4可知迭代格式此时一定收敛.

**注1:** 也可以根据此迭代格式迭代矩阵的行范数小于1, 来判断迭代法收敛.

**注2:** 此迭代格式不能称为原方程组的Jacobi迭代格式, 因为它是对原方程进行预处理后才使用了Jacobi迭代法.

## § 3.4 逐次超松弛迭代法---SOR方法

将Jacobi迭代法

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right),$$

$i=1, 2, \dots, n; k=0, 1, 2, \dots$

改写成

$$x_i^{(k+1)} = x_i^{(k)} + \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^n a_{ij} x_j^{(k)} \right),$$

$i=1, 2, \dots, n; k=0, 1, 2, \dots$

相应的矩阵方程形式就是:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{D}^{-1}(\mathbf{b} - \mathbf{A}\mathbf{x}^{(k)}), \quad k=0, 1, 2, \dots$$



Gauss-Seidel迭代法也可写成

$$x_i^{(k+1)} = x_i^{(k)} + \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right),$$
$$i=1, 2, \dots, n; k=0, 1, 2, \dots$$

或写成矩阵方程形式:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{D}^{-1} [\mathbf{b} + \mathbf{L}\mathbf{x}^{(k+1)} + (\mathbf{U} - \mathbf{D})\mathbf{x}^{(k)}], k=0, 1, 2, \dots$$

还可在此基础上做进一步的改进:

$$x_i^{(k+1)} = x_i^{(k)} + \frac{\omega}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right),$$
$$i=1, 2, \dots, n; k=0, 1, 2, \dots$$

思考: 新格式的意义和优越性是 ...?

迭代格式(分量形式)

$$x_i^{(k+1)} = x_i^{(k)} + \frac{\omega}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right),$$

$i=1, 2, \dots, n; k=0, 1, 2, \dots$

称为**SOR方法(Successive Over Relaxation)**(逐次超松弛迭代法). 其中参数 $\omega$ 称为**松弛因子**.

当 $\omega > 1$ 时称为**超松弛迭代**,

当 $\omega < 1$ 时称为**欠松弛迭代**.

**注1:**  $\omega = 1$ 时SOR方法即为G-S方法.

**注2:** SOR方法可以看作对J迭代法或G-S迭代法的改进.

**注3:** SOR法也可通过某种矩阵分裂的方式而得到. (**思考题**)

SOR方法的矩阵方程形式可写为

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \omega \mathbf{D}^{-1} (\mathbf{b} + \mathbf{L} \mathbf{x}^{(k+1)} + (\mathbf{U} - \mathbf{D}) \mathbf{x}^{(k)}), \quad k=0,1,2,\dots$$

于是有

$$\mathbf{D} \mathbf{x}^{(k+1)} = \mathbf{D} \mathbf{x}^{(k)} + \omega (\mathbf{b} + \mathbf{L} \mathbf{x}^{(k+1)} + (\mathbf{U} - \mathbf{D}) \mathbf{x}^{(k)})$$

**SOR方法的矩阵方程形式**为:

$$\mathbf{x}^{(k+1)} = (\mathbf{D} - \omega \mathbf{L})^{-1} [(1 - \omega) \mathbf{D} + \omega \mathbf{U}] \mathbf{x}^{(k)} + \omega (\mathbf{D} - \omega \mathbf{L})^{-1} \mathbf{b}, \quad k=0,1,2,\dots$$

**SOR方法的迭代矩阵**为

$$\mathbf{f}_{\omega} = (\mathbf{D} - \omega \mathbf{L})^{-1} [(1 - \omega) \mathbf{D} + \omega \mathbf{U}].$$

**定理3.6** 对任意的迭代初始向量,

**SOR方法收敛的充分必要条件**是:  $\rho(\mathbf{f}_{\omega}) < 1$ ;

**SOR方法收敛的充分条件**是:  $\mathbf{f}_{\omega}$ 的某个给定的矩阵范数  $\|\mathbf{f}_{\omega}\|_{\beta} < 1$ .

**定理3.7** 若SOR方法(对任意迭代初始向量)收敛, 则 $0<\omega<2$ .

证明: 设SOR方法收敛, 则 $\rho(\mathbf{f}_\omega)<1$ , 所以

$$|\det(\mathbf{f}_\omega)| = |\lambda_1 \lambda_2 \dots \lambda_n| < 1.$$

而

$$\begin{aligned}\det(\mathbf{f}_\omega) &= \det[(\mathbf{D} - \omega\mathbf{L})^{-1} ((1-\omega)\mathbf{D} + \omega\mathbf{U})] \\ &= \det\{[\mathbf{D}(\mathbf{E} - \omega\mathbf{D}^{-1}\mathbf{L})]^{-1} \mathbf{D}[(1-\omega)\mathbf{E} + \omega\mathbf{D}^{-1}\mathbf{U}]\} \\ &= \det\{(\mathbf{E} - \omega\mathbf{D}^{-1}\mathbf{L})^{-1} \mathbf{D}^{-1} \mathbf{D}[(1-\omega)\mathbf{E} + \omega\mathbf{D}^{-1}\mathbf{U}]\} \\ &= \det[(\mathbf{E} - \omega\mathbf{D}^{-1}\mathbf{L})^{-1}] \det[(1-\omega)\mathbf{E} + \omega\mathbf{D}^{-1}\mathbf{U}] \\ &= (1-\omega)^n.\end{aligned}$$

于是可得  $|1-\omega|<1$ , 也即

$0<\omega<2$ . 证毕.

请思考此定理的意义.

**定理3.8** 设 $A$ 是严格对角占优矩阵, 则解方程组 $Ax=b$ 的SOR方法当 $0<\omega\leq 1$ 时(对任意迭代初始向量)收敛.

定理3.8的证明留作思考题. 教材P68: 3-13.

**定理3.9** 设 $A$ 是对称正定矩阵, 则解方程组 $Ax=b$ 的SOR方法当 $0<\omega< 2$ 时(对任意迭代初始向量)收敛.

## 关于定理3.9的一些预备知识

**命题1** 若 $A$ 为对称正定矩阵, 则 $A$ 的全体对角元素形成的对角矩阵 $D$ 必为正定矩阵.

**定义1** 对于 $C^n$  中的向量 $\mathbf{x}=(x_1, x_2, \dots, x_n)^T$ ,  $\mathbf{y}=(y_1, y_2, \dots, y_n)^T$ , 定义它们的**内积**为如下**复数**:

$$(\mathbf{x}, \mathbf{y}) = x_1 \bar{y}_1 + x_2 \bar{y}_2 + \dots + x_n \bar{y}_n = \mathbf{y}^H \mathbf{x} = \bar{\mathbf{y}}^T \mathbf{x}$$

**复内积的基本性质**: 对于任意的 $\mathbf{x}, \mathbf{y}, \mathbf{z} \in C^n$ , 有

- (1)  $(\mathbf{y}, \mathbf{x}) = \overline{(\mathbf{x}, \mathbf{y})}$ ;
- (2) 对于任意复数 $a, b$ , 有  $(a\mathbf{x} + b\mathbf{y}, \mathbf{z}) = a(\mathbf{x}, \mathbf{z}) + b(\mathbf{y}, \mathbf{z})$  ;
- (3)  $(\mathbf{x}, \mathbf{x}) \geq 0$ ; 且 $(\mathbf{x}, \mathbf{x}) = 0$  当且仅当  $\mathbf{x} = \mathbf{0}$  (零向量).
- (4) 对于 $n$ 阶方阵 $A$ , 成立 $(A\mathbf{x}, \mathbf{y}) = (\mathbf{x}, A^H \mathbf{y})$ .

**定理3.9** 设 $A$ 是对称正定矩阵, 则解方程组 $A\mathbf{x}=\mathbf{b}$ 的SOR方法当 $0<\omega<2$ 时(对任意迭代初始向量)收敛.

证明: 设 $\lambda$ 是 $\mathcal{L}_\omega$ 的任一特征值,  $\mathbf{y}$ 是对应的特征向量, 则

$$(\mathbf{D}-\omega\mathbf{L})^{-1} [(1-\omega)\mathbf{D}+\omega\mathbf{U}]\mathbf{y}=\lambda\mathbf{y},$$

也即:  $[(1-\omega)\mathbf{D}+\omega\mathbf{U}]\mathbf{y}=\lambda(\mathbf{D}-\omega\mathbf{L})\mathbf{y}.$

于是两边分别与 $\mathbf{y}$ 做内积, 可得

$$([(1-\omega)\mathbf{D}+\omega\mathbf{U}]\mathbf{y}, \mathbf{y})=(\lambda(\mathbf{D}-\omega\mathbf{L})\mathbf{y}, \mathbf{y}).$$

也即  $(1-\omega)(\mathbf{D}\mathbf{y}, \mathbf{y})+\omega(\mathbf{U}\mathbf{y}, \mathbf{y})=\lambda[(\mathbf{D}\mathbf{y}, \mathbf{y})-\omega(\mathbf{L}\mathbf{y}, \mathbf{y})].$

故得 
$$\lambda = \frac{(1-\omega)(\mathbf{D}\mathbf{y}, \mathbf{y}) + \omega(\mathbf{U}\mathbf{y}, \mathbf{y})}{(\mathbf{D}\mathbf{y}, \mathbf{y}) - \omega(\mathbf{L}\mathbf{y}, \mathbf{y})}.$$

由于 $A=\mathbf{D}-\mathbf{L}-\mathbf{U}$ 是对称正定的, 所以 $\mathbf{D}$ 是正定矩阵, 且 $\mathbf{L}=\mathbf{U}^T$ .

由 $\mathbf{D}$ 的正定性可得

$$(\mathbf{D}\mathbf{y}, \mathbf{y}) = \sigma > 0.$$

由 $\mathbf{U} = \mathbf{L}^T$ , 以及复内积的定义, 注意此时 $\mathbf{L}^T = \mathbf{L}^H$ , 可得

$$(\mathbf{U}\mathbf{y}, \mathbf{y}) = (\mathbf{L}^T\mathbf{y}, \mathbf{y}) = (\mathbf{y}, \mathbf{L}\mathbf{y}) = \overline{(\mathbf{L}\mathbf{y}, \mathbf{y})}.$$

所以, 若记 $(\mathbf{L}\mathbf{y}, \mathbf{y}) = \alpha + i\beta$ , 则有 $(\mathbf{U}\mathbf{y}, \mathbf{y}) = \alpha - i\beta$ .

根据 $\mathbf{A}$ 的正定性, 以及以上的分析, 可得

$$0 < (\mathbf{A}\mathbf{y}, \mathbf{y}) = (\mathbf{D}\mathbf{y}, \mathbf{y}) - (\mathbf{L}\mathbf{y}, \mathbf{y}) - (\mathbf{U}\mathbf{y}, \mathbf{y}) = \sigma - 2\alpha.$$

再由  
可得

$$\lambda = \frac{(1 - \omega)(\mathbf{D}\mathbf{y}, \mathbf{y}) + \omega(\mathbf{U}\mathbf{y}, \mathbf{y})}{(\mathbf{D}\mathbf{y}, \mathbf{y}) - \omega(\mathbf{L}\mathbf{y}, \mathbf{y})}$$

$$\lambda = \frac{(1 - \omega)\sigma + \omega(\alpha - i\beta)}{\sigma - \omega(\alpha + i\beta)}$$



于是

$$|\lambda|^2 = \frac{(\sigma - \sigma\omega + \omega\alpha)^2 + \omega^2\beta^2}{(\sigma - \omega\alpha)^2 + \omega^2\beta^2}$$

当 $0 < \omega < 2$ 时, 观察上述分式, 可得

$$\begin{aligned} \text{分子-分母} &= (\sigma - \sigma\omega + \omega\alpha)^2 - (\sigma - \omega\alpha)^2 \\ &= (2\omega\alpha - \sigma\omega)(2\sigma - \sigma\omega) \\ &= \omega\sigma(2\alpha - \sigma)(2 - \omega) \\ &< 0 \end{aligned}$$

$$0 < (Ay, y) = \sigma - 2\alpha.$$

所以 $|\lambda|^2 < 1$ , 因此 $\rho(\mathbf{L}_\omega) < 1$ , 即**SOR**方法收敛. 证毕.

**推论(定理3.5):** 当 $A$ 是对称正定矩阵时, 解方程组 $A\mathbf{x}=\mathbf{b}$ 的 Gauss-Seidel方法(对任意迭代初始向量)必定收敛.

**补充1:** 借鉴定理3.9的证明思路, 还可以推得如下结论.

设 $\lambda$ 是Jacobi迭代矩阵 $\mathbf{B}$ 的任一特征值,  $\mathbf{y}$ 是特征向量, 则

$$(\mathbf{L} + \mathbf{U})\mathbf{y} = \lambda \mathbf{D}\mathbf{y}.$$

于是  $(\mathbf{L}\mathbf{y}, \mathbf{y}) + (\mathbf{U}\mathbf{y}, \mathbf{y}) = \lambda(\mathbf{D}\mathbf{y}, \mathbf{y})$ .

由定理3.9的证明可得:  $\lambda = 2\alpha / \sigma$ .

此外还可知, 当 $\mathbf{A}$ 对称正定时, 必有 $\sigma > 0$ ,  $2\alpha - \sigma < 0$ ; 此时,

$$|\lambda| < 1 \Leftrightarrow |2\alpha / \sigma| < 1 \Leftrightarrow 2\alpha + \sigma > 0,$$

而  $((2\mathbf{D} - \mathbf{A})\mathbf{y}, \mathbf{y}) = (\mathbf{D}\mathbf{y}, \mathbf{y}) + (\mathbf{L}\mathbf{y}, \mathbf{y}) + (\mathbf{U}\mathbf{y}, \mathbf{y}) = \sigma + 2\alpha$ ,

因此可得:

当 $\mathbf{A}$ 与 $2\mathbf{D} - \mathbf{A}$ 均对称正定时, **Jacobi**迭代法必收敛.

此外还可证明(留作思考题):

当 $\mathbf{A}$ 对称正定且**Jacobi**迭代法收敛时必有 $2\mathbf{D} - \mathbf{A}$ 正定.

**补充2:** 根据定理3.9的证明思路, 还可以证明(只需对证明过程稍作修改):

设  $A$  是对称 **负** 定矩阵. 则解方程组  $A\mathbf{x}=\mathbf{b}$  的 **SOR** 方法当  $0<\omega<2$  时(对任意迭代初始向量)也收敛.

# 总结

解方程组 $Ax=b$ 时, 各算法(对任意迭代初始向量)的收敛性

	J迭代法	G-S迭代法	SOR方法
当 $A$ 严格对角占优时	收敛	收敛	当 $0<\omega\leq 1$ 时收敛
当 $A$ 对称正定(或负定)时	未必收敛	收敛	当 $0<\omega<2$ 时收敛

SOR方法收敛的快慢与松弛因子 $\omega$ 的选择有密切关系. 但是如何选取最佳松弛因子, 即选取 $\omega=\omega^*$ , 使 $\rho(\mathbf{L}_{\omega^*})$ 达到最小, 是一个尚未很好解决的问题. 实际应用中有时可采用试算的方法来确定较好的松弛因子.

注1: 对于具有对称正定系数矩阵的线性方程组, 目前比较成熟的高效算法有CG(Conjugate Gradient)算法, 即共轭梯度法, 或者辅以预条件技术的预条件共轭梯度(Preconditioned Conjugate Gradient)算法.

注2: 此外, 对于满足一定条件的线性方程组, 近代也涌现出诸如极小残量法(MINRES)、广义极小残量法(GMRES)等一些高效的算法. 有关新算法的理论研究和实践正在发展中.

#### 例4 用SOR方法解线性方程组

$$\begin{cases} 4x_1 - 2x_2 - 4x_3 = 10 \\ -2x_1 + 17x_2 + 10x_3 = 3 \\ -4x_1 + 10x_2 + 9x_3 = -7 \end{cases}$$

方程组的精确解是 $\mathbf{x}^*=(2, 1, -1)^T$ .

解: **SOR**方法迭代公式为

$$\begin{cases} x_1^{(k+1)} = x_1^{(k)} + \frac{\omega}{4}(10 - 4x_1^{(k)} + 2x_2^{(k)} + 4x_3^{(k)}) \\ x_2^{(k+1)} = x_2^{(k)} + \frac{\omega}{17}(3 + 2x_1^{(k+1)} - 17x_2^{(k)} - 10x_3^{(k)}) \\ x_3^{(k+1)} = x_3^{(k)} + \frac{\omega}{9}(-7 + 4x_1^{(k+1)} - 10x_2^{(k+1)} - 9x_3^{(k)}) \end{cases}$$

取 $\mathbf{x}^{(0)}=(0, 0, 0)^T$ ,  $\omega=1.46$ , 计算结果如下:

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$
0	0	0	0
1	3.65	0.8845882	-0.2021098
2	2.32166910	0.4230939	-0.22243214
3	2.5661399	0.6948261	-0.4952594
...	.....	.....	.....
20	1.9999987	1.0000013	-1.0000034

从结果可见，迭代20次时已获得精确到小数点后五位的近似解. 如果取 $\omega=1.25$ ，则需要迭代56次才能得到具有同样精度的近似解；如果取 $\omega=1$ ，则需迭代110次以上.

# 课堂练习

设线性方程组

$$\begin{cases} 4x_1 - x_2 + 2x_3 = 1 \\ -x_1 - 5x_2 + x_3 = 2 \\ 2x_1 + x_2 + 6x_3 = 3 \end{cases}$$

- (1) 写出Jacobi法和SOR法的迭代格式(分量形式);
- (2) 讨论Jacobi迭代法的收敛性;
- (3) 取初值 $\mathbf{x}^{(0)}=(0, 0, 0)^T$ , 若用Jacobi迭代法计算时, 预估误差 $\|\mathbf{x}^*-\mathbf{x}^{(10)}\|_\infty$  (取三位有效数字).



解: (1) Jacobi迭代法格式为

$$\begin{cases} x_1^{(k+1)} = \frac{1}{4}x_2^{(k)} - \frac{1}{2}x_3^{(k)} + \frac{1}{4} \\ x_2^{(k+1)} = -\frac{1}{5}x_1^{(k)} + \frac{1}{5}x_3^{(k)} - \frac{2}{5} \\ x_3^{(k+1)} = -\frac{1}{3}x_1^{(k)} - \frac{1}{6}x_2^{(k)} + \frac{1}{2} \end{cases}$$

SOR法的迭代格式为

$$\begin{cases} x_1^{(k+1)} = x_1^{(k)} + \omega(-x_1^{(k)} + \frac{1}{4}x_2^{(k)} - \frac{1}{2}x_3^{(k)} + \frac{1}{4}) \\ x_2^{(k+1)} = x_2^{(k)} - \omega(\frac{1}{5}x_1^{(k+1)} + x_2^{(k)} - \frac{1}{5}x_3^{(k)} + \frac{2}{5}) \\ x_3^{(k+1)} = x_3^{(k)} - \omega(\frac{1}{3}x_1^{(k+1)} + \frac{1}{6}x_2^{(k+1)} + x_3^{(k)} - \frac{1}{2}) \end{cases}$$

(2) 因为系数矩阵 $A$ 是严格对角占优矩阵, 故Jacobi法收敛.

(3) 由(1)可见 $\|B\|_{\infty}=3/4$ , 且取 $\mathbf{x}^{(0)}=(0, 0, 0)^T$ , 经计算可得 $\mathbf{x}^{(1)}=(1/4, -2/5, 1/2)^T$ , 于是 $\|\mathbf{x}^{(1)}-\mathbf{x}^{(0)}\|_{\infty}=1/2$ , 所以有

$$\left\| \mathbf{x}^* - \mathbf{x}^{(10)} \right\|_{\infty} \leq \frac{\|B\|_{\infty}^k}{1 - \|B\|_{\infty}} \left\| \mathbf{x}^{(1)} - \mathbf{x}^{(0)} \right\|_{\infty} = \frac{0.75^{10}}{1 - 0.75} \times 0.5 = 0.113$$